FIT&PREDICT

УЧЕБНИК МАШИННОГО ОБУЧЕНИЯ

Линейная регрессия.

Модель. Доказательства. Статистика.

От производных и ковариации до матричной проекции, случайного шума и доверительных интервалов. Пошаговые выводы, вычислительные примеры и границы применимости.

Редакция для совместной работы · 19 октября 2026
37 разделов из теории сайта · формулы в векторном формате
Оглавление и ссылки на источники кликабельны.

МАРШРУТ ЧТЕНИЯ

Содержание

Три взгляда на одну модель: математический анализ, линейная алгебра, теория вероятностей и статистика.

1. Линейная регрессия

01 Одна модель. Три разных вопроса.

02 Наблюдения, параметры и случайные величины

03 Линейность относится к параметрам

04 Квадратичная ошибка и роль смещения

05 Находим прямую через частные производные

06 Наклон — совместное изменение, делённое на разброс

07 Числа, которые можно проверить вручную

08 Normal equations: от дифференциала к весам

09 Когда веса не единственны

10 Почему остаток перпендикулярен признакам

11 Что вычисляет кнопка «Один шаг»

12 Локальное направление убывания

13 Learning rate ограничивает спектр

14 Почему похожие признаки замедляют обучение

15 Число шагов и число просмотренных объектов

16 Случайный шум не обязан быть нормальным

17 Вывод максимального правдоподобия

18 Выбор плотности меняет функцию потерь

19 Насколько случайны найденные коэффициенты

20 В каком смысле МНК оптимален

21 От остатков к статистической неопределённости

22 Почему предиктивный интервал шире

23 Взвешивание и корректные стандартные ошибки

24 Чего не исправит большая выборка

25 Добавляем штраф, сохраняя свободный член

26 За устойчивость платим смещением

27 Почему L1 может дать ровно нулевой вес

28 MAP и распределение весов после данных

29 Доказательство bias² + variance + noise

30 Когда прямая — слишком узкая гипотеза

31 Среднее, медиана и квантиль отвечают на разные вопросы

32 От доказанного минимума к полезному прогнозу

33 Риск — ожидание по будущим объектам

34 Что смотреть после обучения

35 Коэффициент и причинное воздействие

36 Три коротких вывода своими руками

37 Где продолжить разбор

ГЛАВА 1

Линейная регрессия.

От производных a и b до матричной проекции, случайного шума и доверительных интервалов. Доказываем формулы и разбираем границы их применимости.

01 / ТРИ ВЗГЛЯДА НА РЕГРЕССИЮ

Одна модель. Три разных вопроса.

Как по часам подготовки предсказать балл? Сначала найдём прямую, которая лучше всего приближает уже известные ответы. Затем докажем, почему найденные коэффициенты минимизируют ошибку. Наконец спросим: насколько они изменились бы, если бы мы собрали другую выборку?

Математический анализ

Производные находят минимум. Ковариация объясняет наклон прямой.

Линейная алгебра

МНК - проекция. Ранг определяет единственность весов, спектр - устойчивость.

Теория вероятностей

Шум делает оценки случайными. Предположения определяют их точность и допустимые выводы.

Понадобятся производная, скалярное произведение, математическое ожидание и дисперсия. Новые обозначения вводятся рядом с доказательствами. Первые разделы обходятся без матриц; к статистике можно вернуться после экспериментов с весами.

> **Что мы считаем доказательством.** У каждого результата есть условия, вычисления и вывод. Формула с обратной матрицей без проверки ранга или доверительный интервал без модели шума - ещё не законченный результат.

02 / ОБОЗНАЧЕНИЯ

Наблюдения, параметры и случайные величины

Обозначения в этом разделе

n, d, $p=d+1$	число наблюдений, исходных признаков и параметров с учётом смещения
x_i, y_i	известные значения признака и ответа в одномерном примере
a, b	наклон и смещение в модели $\hat{y}=ax+b$; в некоторых источниках эти буквы переставлены
$\bar{x}$, $\bar{y}$	средние по наблюдаемой выборке: $\Sigma x_i/n$ и $\Sigma y_i/n$
$X_o \in \mathbb{R}^{n\times d}$	таблица исходных признаков без столбца единиц
$X=[1\ X_o] \in \mathbb{R}^{n\times p}$	матрица дизайна с первым столбцом из единиц
$\beta=(b,w_1,\dots,w_d)^T$	общий столбец параметров; $\hat{\beta}$ - его оценка по данным
y, $\hat{y} \in \mathbb{R}^n$	столбец ответов и столбец прогнозов: $\hat{y}=X\beta$
$e=y-\hat{y}$, $r=\hat{y}-y=-e$	остатки; оба знака встречаются в литературе, квадрат одинаков
ε	ненаблюдаемый случайный шум в истинном механизме, не то же самое, что остаток e
E, Var, Cov	математическое ожидание, дисперсия и ковариация
U, Y	случайные признак и ответ; букву X далее оставляем для матрицы
$\|v\|_2^2=\Sigma v_j^2$	квадрат евклидовой нормы
A^T, I, $tr(A)$	транспонирование, единичная матрица и сумма диагональных элементов

Условная запись $E[\varepsilon|X]=0$ означает: после фиксации *всей* матрицы признаков средний шум равен нулю. В чисто алгебраической части X и y - просто заданные числа. Статистические предпосылки понадобятся позже.

03 / МОДЕЛЬ И ЗАДАЧА

Линейность относится к параметрам

$$\hat{y}_i = b + \sum_{j=1}^{d} w_j x_{ij}, \qquad \hat{y} = X\beta$$

Одна строка матрицы X умножается на β и даёт один прогноз.

Коэффициент w_j - изменение прогноза на единицу j-го признака при фиксированных остальных. Его единицы - единицы ответа, делённые на единицы признака. Измерить площадь в м² или см² означает получить разные численные веса при том же прогнозе.

Модель $b+w_1x+w_2x^2$ тоже линейная по весам. Нелинейна она по исходному x. А модель exp(wx) уже нелинейна по w. Дальнейший МНК применим к любым заранее выбранным столбцам X, включая полиномиальные признаки.

04 / ЧТО МИНИМИЗИРУЕМ

Квадратичная ошибка и роль смещения

$$J(\beta) = \frac{1}{n}\|X\beta - y\|_2^2 = \frac{1}{n}\sum_i (\hat{y}_i - y_i)^2$$

МНК / OLS - метод наименьших квадратов. SSE=nJ - сумма квадратов ошибок.

Все дальнейшие градиенты соответствуют именно MSE с множителем 1/n. Если взять SSE или J/2, точка минимума не изменится, но градиент и допустимый learning rate изменятся. При добавлении регуляризации её относительный масштаб тоже необходимо пересчитать.

МНК измеряет ошибки по вертикали, в единицах ответа. Он не симметричен по признакам и таргету. Обучить x по y и перевернуть получившуюся прямую - обычно другое решение. Для существенных ошибок измерения в самих признаках нужна отдельная модель.

05 / ВЫВОД A И B

Находим прямую через частные производные

Пусть $n \geq 2$ и не все x_i равны. Минимизируем $J(a,b)=\Sigma(ax_i+b-y_i)^2/n$ одновременно по a и b.

От производных до формул

1

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_i (ax_i + b - y_i) = 0$$

Производная внутреннего выражения по b равна 1.

2

$$a\sum_i x_i + nb - \sum_i y_i = 0 \quad \Longrightarrow \quad \hat{b} = \overline{y} - \hat{a}\,\overline{x}$$

Прямая МНК со свободным членом проходит через точку $(\bar{x},\bar{y})$.

3 $$\frac{\partial J}{\partial a} = \frac{2}{n}\sum_i x_i(ax_i + b - y_i) = 0$$

По цепному правилу появляется множитель x_i.

4 $$\hat{a}\sum_i x_i(x_i - \overline{x}) = \sum_i x_i(y_i - \overline{y})$$

Подставляем $\hat{b}=\bar{y}-\hat{a}\bar{x}$ в уравнение по a.

5 $$\sum_i x_i(x_i - \overline{x}) = \sum_i (x_i - \overline{x})^2,$$
$$\sum_i x_i(y_i - \overline{y}) = \sum_i (x_i - \overline{x})(y_i - \overline{y})$$

Добавленные средние исчезают, потому что суммы центрированных значений равны нулю.

6 $$S_{xx} = \sum_i (x_i - \overline{x})^2, \qquad S_{xy} = \sum_i (x_i - \overline{x})(y_i - \overline{y})$$

Обозначаем два вычисляемых по данным числа.

7 $$\boxed{\hat{a} = \frac{S_{xy}}{S_{xx}}, \qquad \hat{b} = \overline{y} - \hat{a}\,\overline{x}}$$

$S_{xx}>0$ по условию: деление допустимо.

Почему стационарная точка - единственный минимум

1 $$\nabla^2 J = \frac{2}{n}\begin{pmatrix} \sum_i x_i^2 & \sum_i x_i \\ \sum_i x_i & n \end{pmatrix}$$

Гессиан - матрица вторых производных по (a,b).

2 $$(u, v)\nabla^2 J (u, v)^\top = \frac{2}{n}\sum_i (ux_i + v)^2$$

Квадратичная форма неотрицательна. При разных x_i она равна нулю только при u=v=0.

3 $$\det(\nabla^2 J) = \frac{4}{n^2}\left[n\sum_i x_i^2 - \left(\sum_i x_i\right)^2\right] = \frac{4S_{xx}}{n} > 0$$

Гессиан положительно определён; функция строго выпуклая. Найденная точка - глобальный единственный минимум.

Вырожденный случай. Если $x_i=c$ для всех i, то $S_{xx}=0$: данные не различают a и b. Любая пара $ac+b=\bar{y}$ минимизирует ошибку. Если же заранее запретить смещение, получится $\hat{a}=\Sigma x_i y_i / \Sigma x_i^2$, а не формула через центрированную ковариацию.

06 / КОВАРИАЦИЯ И КОРРЕЛЯЦИЯ

Наклон - совместное изменение, делённое на разброс

$$\mathrm{Cov}_n(x,y)=\frac{S_{xy}}{n},\quad \mathrm{Var}_n(x)=\frac{S_{xx}}{n},$$
$$\widehat{a}=\frac{\mathrm{Cov}_n(x,y)}{\mathrm{Var}_n(x)}=\rho_n\frac{s_y}{s_x}$$

$s_x^2=S_{xx}/n$, $s_Y^2=\Sigma(y_i-\bar{y})^2/n$; корреляция ρ_n определена при $s_x,s_Y>0$. Если в ковариации и дисперсии одновременно взять $n-1$, отношение не изменится.

Ковариация положительна, когда отклонения x и y от своих средних чаще направлены одинаково. Деление на дисперсию x переводит совместное изменение в изменение y на единицу x. После стандартизации обоих столбцов наклон равен корреляции.

Та же связь для случайных величин

1 $$R(a,b)=\mathbb{E}[(Y-aU-b)^2],\quad \mathbb{E}[U^2],\mathbb{E}[Y^2]<\infty,\quad \mathrm{Var}(U)>0$$

Это риск по распределению, а не среднее по конкретным строкам. Раскрыв квадрат, получаем полином по a,b.

2 $$\frac{\partial R}{\partial b}=2(a\mathbb{E}[U]+b-\mathbb{E}[Y])=0,$$
$$b^*=\mathbb{E}[Y]-a^*\mathbb{E}[U]$$

Оптимальное смещение снова центрирует модель.

3 $$R(a,b^*(a))=\mathrm{Var}(Y)-2a\,\mathrm{Cov}(U,Y)+a^2\,\mathrm{Var}(U)$$

Подставляем смещение и раскрываем квадрат центрированных величин.

4 $$\frac{\partial R}{\partial a}=-2\,\mathrm{Cov}(U,Y)+2a\,\mathrm{Var}(U)=0,$$
$$a^*=\frac{\mathrm{Cov}(U,Y)}{\mathrm{Var}(U)}$$

Вторая производная $2\mathrm{Var}(U)>0$ доказывает единственность.

5

$$Y = a_0 U + b_0 + \varepsilon \quad \Longrightarrow \quad a^* = a_0 + \frac{\operatorname{Cov}(U, \varepsilon)}{\operatorname{Var}(U)}$$

Коэффициент восстанавливает a_0 лишь при отсутствии линейной связи признака с ошибкой. $E[\varepsilon|U]=0$ достаточно для $\operatorname{Cov}(U,\varepsilon)=0$.

Нулевая ковариация не доказывает независимость. Например, для U, равномерного на [−1,1], и $Y=U^2$ получаем $\operatorname{Cov}(U,Y)=E[U^3]=0$. Лучшая прямая - константа $E[Y]=1/3$, хотя Y полностью определяется U. Так линейная модель может пропустить сильную нелинейную закономерность.

Продолжить чтение: Андрей Хлевнюк - «Основы линейной регрессии» ↗

07 / ПРИМЕР НА ЧЕТЫРЁХ ТОЧКАХ

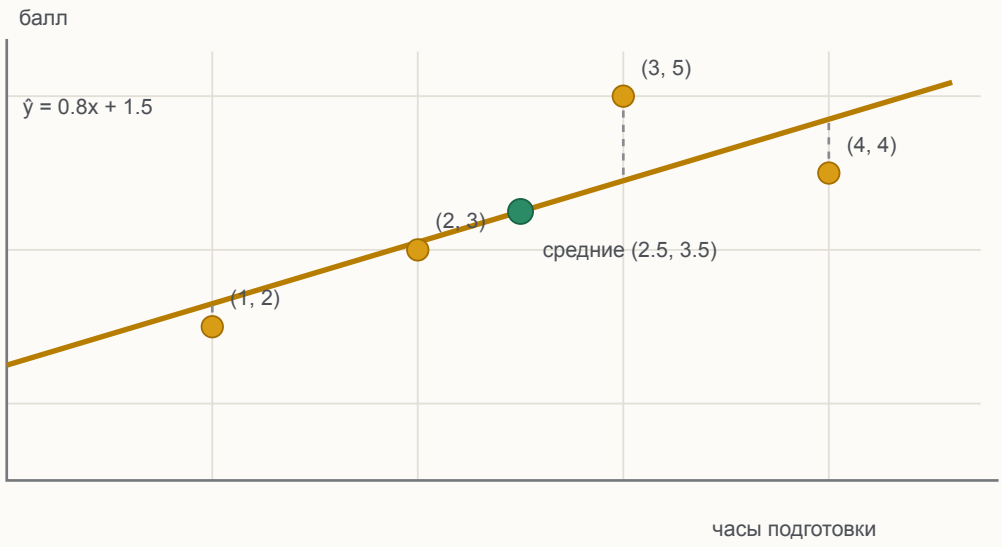
Числа, которые можно проверить вручную

Возьмём искусственные данные: часы подготовки x=(1,2,3,4) и условные баллы y=(2,3,5,4). Это вычислительный пример, а не утверждение о реальной зависимости успеваемости.

Полный расчёт одномерного МНК

x	y	x−x̄	y−ȳ	(x−x̄)(y−ȳ)	ŷ	e=y−ŷ
1	2	−1.5	−1.5	2.25	2.3	−0.3
2	3	−0.5	−0.5	0.25	3.1	−0.1
3	5	0.5	1.5	0.75	3.9	1.1
4	4	1.5	0.5	0.75	4.7	−0.7

$$\overline{x} = 2.5, \quad \overline{y} = 3.5, \quad S_{xx} = 5, \quad S_{xy} = 4,$$
$$\widehat{a} = 0.8, \quad \hat{b} = 1.5, \quad \mathrm{SSE} = 1.8, \quad \mathrm{MSE} = 0.45$$



Линия проходит через средние. Пунктир - вертикальные ошибки на наблюдениях; МНК минимизирует сумму их квадратов, а не перпендикулярные расстояния до прямой.

Проверка оптимальности: $\Sigma e_i=0$ и $\Sigma x_i e_i=-0.3-0.2+3.3-2.8=0$. Значит, обе частные производные равны нулю. Эти равенства получились благодаря обучению; они сами по себе не доказывают, что ненаблюдаемый шум независим от признаков.

08 / МАТРИЧНЫЙ ДИФФЕРЕНЦИАЛ

Normal equations: от дифференциала к весам

Теперь p параметров, $X\in\mathbb{R}^{n\times p}$ и $\beta\in\mathbb{R}^{p}$. При дифференцировании X и y фиксированы. Малое приращение dβ - столбец той же размерности, что β. Для скалярной функции $dJ=(\nabla J)^{\top}d\beta$.

Дифференцируем матричную запись

1

$$r = X\beta - y, \qquad J = \frac{r^{\top}r}{n}, \qquad dr = X\,d\beta$$

Линейность умножения даёт дифференциал остатка без покоординатного разворачивания.

2

$$dJ = \frac{(dr)^{\top}r + r^{\top}dr}{n} = \frac{2}{n}r^{\top}dr$$

Оба слагаемых - одно и то же число: скаляр равен своему транспонированию.

3

$$dJ = \frac{2}{n}r^{\top}X\,d\beta = \left[\frac{2}{n}X^{\top}r\right]^{\top}d\beta$$

Переставляем только через транспонирование; порядок матриц нельзя менять произвольно.

4

$$\nabla J(\beta) = \frac{2}{n} X^\top (X\beta - y), \qquad \nabla^2 J = \frac{2}{n} X^\top X$$

Считываем коэффициент перед dβ и дифференцируем ещё раз.

5

$$\nabla J = 0 \quad \Longleftrightarrow \quad X^\top X \widehat{\beta} = X^\top y$$

Это нормальные уравнения. «Нормальные» означает ортогональность, а не гауссовский шум.

6

$$\operatorname{rank}(X) = p \quad \Longrightarrow \quad \boxed{\widehat{\beta} = (X^\top X)^{-1} X^\top y}$$

Обратная существует при линейно независимых столбцах, в частности n≥p.

7

$$h^\top \nabla^2 J h = \frac{2}{n} \|Xh\|^2 > 0 \qquad (h \neq 0)$$

При полном столбцовом ранге получаем строгую выпуклость и единственный глобальный минимум.

Тот же градиент получается из $J=(\beta^\top X^\top X\beta - 2y^\top X\beta + y^\top y)/n$: для постоянной A производная $\beta^\top A\beta$ равна $(A+A^\top)\beta$. Здесь $A=X^\top X$ симметрична. Формула «2Aβ» без симметрии неверна.

$$X^\top X \in \mathbb{R}^{p \times p}, \qquad X^\top y \in \mathbb{R}^{p \times 1}, \qquad \widehat{\beta} \in \mathbb{R}^{p \times 1}$$

Свободный член уже включён первым элементом β. Нельзя после этой формулы ещё раз прибавлять отдельный обученный b.

Продолжить чтение: Яндекс Учебник - линейные модели ↗

09 / РАНГ, QR И SVD

Когда веса не единственны

Пусть два столбца X совпадают. Их коэффициенты могут компенсироваться: добавить t к одному и вычесть t из другого можно без изменения прогнозов. В общем случае это направление h из ядра X: Xh=0.

Все решения через компактное SVD

1

$$X = U_r \Sigma_r V_r^\top, \quad \operatorname{rank}(X) = r, \quad \Sigma_r = \operatorname{diag}(s_1, \ldots, s_r),\ s_j > 0$$

Столбцы U_r и V_r ортонормированы. Разложение оставляет только ненулевые сингулярные значения.

2

$$\|y - X\beta\|^2 = \|U_r^\top y - \Sigma_r V_r^\top \beta\|^2 + \|(I - U_r U_r^\top) y\|^2$$

Разлагаем y на компоненту в пространстве столбцов X и ортогональное дополнение. По теореме Пифагора их квадраты норм складываются. Второе слагаемое не зависит от β.

3

$$\Sigma_r V_r^\top \beta = U_r^\top y \quad \Longrightarrow \quad V_r^\top \beta = \Sigma_r^{-1} U_r^\top y$$

Первое слагаемое можно обнулить. Все диагональные значения Σ_r положительны, поэтому обращение допустимо.

4

$$X^+ = V_r \Sigma_r^{-1} U_r^\top, \qquad \widehat{\beta}_0 = X^+ y$$

Псевдообратная определена и при r<p.

5

$$\widehat{\beta} = X^+ y + h, \qquad h \in \ker(X)$$

Все МНК-решения различаются только невидимой для данных компонентой.

6

$$\hat{y} = X X^+ y = U_r U_r^\top y$$

Вектор прогнозов на train единственен, даже когда коэффициенты не единственны.

7

$$\|\widehat{\beta}_0 + h\|^2 = \|\widehat{\beta}_0\|^2 + \|h\|^2$$

$\hat{\beta}_0$ лежит в пространстве строк X, ортогональном ядру; это решение минимальной нормы.

При n<p полный столбцовый ранг невозможен. При полном строковом ранге r=n любой y можно интерполировать с нулевой train-ошибкой. Из этого не следует качество на новых данных: $x_0^\top h$ может быть ненулевым для объекта вне обучающих строк.

На практике обычно не строят $(X^\top X)^{-1}$ явно. При полном ранге тонкое QR-разложение X=QR превращает задачу в треугольную систему $R\hat{\beta}=Q^\top y$. SVD выявляет почти зависимые направления. Для спектрального числа обусловленности $\kappa_2(X^\top X)=\kappa_2(X)^2$: нормальные уравнения усиливают численную неустойчивость.

10 / ПРОЕКЦИЯ И R^2

Почему остаток перпендикулярен признакам

Геометрическое доказательство МНК

1

$$P = X X^+ = U_r U_r^\top, \qquad P^\top = P, \qquad P^2 = P$$

P - ортогональный проектор на пространство столбцов X.

2

$$\hat{y} = Py, \qquad e = (I - P)y, \qquad X^\top e = 0$$

Остаток ортогонален всему пространству допустимых прогнозов.

3

$$y - X\beta = e + (\hat{y} - X\beta)$$

Первое слагаемое перпендикулярно второму.

4

$$\|y - X\beta\|^2 = \|e\|^2 + \|\hat{y} - X\beta\|^2 \geq \|e\|^2$$

Теорема Пифагора доказывает глобальный минимум без производных.

Если в X есть столбец единиц, то $1^T e=0$, среднее прогнозов равно $\bar{y}$ и e ортогонален $\hat{y}-\bar{y}1$. При $S_{YY}=\Sigma(y_i-\bar{y})^2>0$ получаем:

$$S_{yy} = \|y - \bar{y}\mathbf{1}\|^2 = \|\hat{y} - \bar{y}\mathbf{1}\|^2 + \mathrm{SSE},$$
$$R^2 = 1 - \frac{\mathrm{SSE}}{S_{yy}} \in [0, 1]$$

Для одного признака $\hat{a}=S_{xy}/S_{xx}$, поэтому $\|\hat{y}-\bar{y}1\|^2=\hat{a}^2S_{xx}=S_{xy}^2/S_{xx}$ и $R^2=S_{xy}^2/(S_{xx}S_{yy})=\rho_n^2$. В нашем примере $R^2=16/25=0.64$. Для нескольких признаков это не квадрат корреляции с каким-то одним признаком.

Разложение и границы [0,1] относятся к МНК **на train со смещением**. На validation/test R^2 может быть отрицательным. Без смещения или при штрафе ортогональное разложение выше не гарантировано. При постоянном y знаменатель равен нулю.

11 / ПОКООРДИНАТНЫЙ ГРАДИЕНТ

Что вычисляет кнопка «Один шаг»

Цепное правило по каждому весу

1

$$r_i = b + \sum_j w_j x_{ij} - y_i, \qquad J = \frac{1}{n}\sum_i r_i^2$$

Фиксируем знак ошибки: прогноз минус ответ.

2

$$\frac{\partial r_i}{\partial w_j} = x_{ij}, \qquad \frac{\partial r_i}{\partial b} = 1$$

Меняем только один параметр, всё остальное считаем постоянным.

3

$$\frac{\partial (r_i^2)}{\partial w_j} = 2 r_i x_{ij}$$

Производная внешнего квадрата умножается на производную остатка.

4

$$\frac{\partial J}{\partial w_j} = \frac{2}{n}\sum_i r_i x_{ij}$$

Усредняем вклад всех наблюдений.

5

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_i r_i$$

У столбца смещения вместо признака стоят единицы.

6

$$w_j \leftarrow w_j - \eta\frac{\partial J}{\partial w_j}, \qquad b \leftarrow b - \eta\frac{\partial J}{\partial b}$$

Все производные в одном шаге вычисляются на одном и том же старом векторе параметров.

На четырёх точках при a=b=0: ∂J/∂a=−19.5 и ∂J/∂b=−7. При η=0.05 первый шаг даст a=0.975, b=0.35. Это ещё не оптимум (0.8,1.5), хотя оба параметра уже изменились в сторону уменьшения MSE.

12 / ПОЧЕМУ ПРОТИВ ГРАДИЕНТА

Локальное направление убывания

Тейлор и Коши-Буняковский

1

$$J(\beta + hv) = J(\beta) + h\langle \nabla J(\beta), v\rangle + o(h), \qquad \|v\|_2 = 1$$

Первое приближение по Тейлору задаёт производную по направлению.

2

$$\langle \nabla J, v\rangle \geq -\|\nabla J\|_2\|v\|_2 = -\|\nabla J\|_2$$

Неравенство Коши-Буняковского ограничивает возможную скорость убывания.

3

$$v^* = -\frac{\nabla J}{\|\nabla J\|_2} \qquad (\nabla J \neq 0)$$

В этом направлении нижняя граница достигается. При нулевом градиенте все производные первого порядка равны нулю.

Это утверждение про бесконечно малый шаг в евклидовой норме. Для конечного η нужен контроль кривизны: даже правильное направление с чрезмерным шагом увеличивает loss.

Learning rate ограничивает спектр

Обозначим $H=2X^TX/n$. При полном столбцовом ранге его собственные значения $0<\mu_1\le\ldots\le\mu_p$. Пусть $q_t=\beta_t-\hat{\beta}$ - ошибка параметров.

Что происходит с ошибкой на каждом шаге

1 $$\nabla J(\beta_t) = H(\beta_t - \hat{\beta}), \qquad q_{t+1} = (I - \eta H) q_t$$

Вычитаем нормальные уравнения из текущего градиента.

2 $$H = V\,\mathrm{diag}(\mu_j)V^\top, \qquad c_t = V^\top q_t$$

Переходим в ортонормированный базис собственных векторов.

3 $$c_{t+1,j} = (1 - \eta\mu_j)c_{t,j}$$

Каждое направление теперь живёт независимо.

4 $$|1 - \eta\mu_j| < 1 \;\; (\forall j) \quad\Longleftrightarrow\quad 0 < \eta < \frac{2}{\mu_p}$$

Все компоненты затухают; отсюда $\beta_t\to\hat{\beta}$.

5 $$\|q_t\|_2 \le \rho^t \|q_0\|_2, \qquad \rho = \max_j |1 - \eta\mu_j| < 1$$

Получаем количественную геометрическую скорость сходимости.

При $\eta=2/\mu_p$ старшая компонента меняет знак без уменьшения; выше границы растёт, если присутствовала в начальной ошибке. При неполном ранге нулевые направления не меняются: прогнозы сходятся, а компоненту весов в ядре сохраняет инициализация.

$$J(\beta - \eta g) = J(\beta) - \eta\|g\|^2 + \frac{\eta^2}{2} g^\top H g, \qquad g = \nabla J(\beta)$$

Для квадратичной функции формула Тейлора точна. При $0<\eta<2/\mu_p$ и $g\neq0$ из $g^THg\le\mu_p\|g\|^2$ следует строгое убывание.

Практическая остановка - достижение заданной точности, а не точное равенство весов. Малый шаг может означать маленький η. Округлённый до 0.000 градиент может быть ненулевым. При полном ранге $J(\beta)-J(\hat{\beta})\le\|\nabla J(\beta)\|^2/(2\mu_1)$, поэтому один и тот же маленький градиент даёт разные гарантии при разной обусловленности.

14 / МАСШТАБ И ОБУСЛОВЛЕННОСТЬ

Почему похожие признаки замедляют обучение

Число $\kappa=\mu_p/\mu_1$ измеряет вытянутость квадратичной чаши. Для постоянного шага $\eta^*=2/(\mu_1+\mu_p)$ худший множитель сжатия равен $(\kappa-1)/(\kappa+1)$. Если κ огромно, он почти равен 1: тысячи шагов могут мало менять слабое направление.

После стандартизации столбцы получают сравнимые масштабы, но почти линейная зависимость не исчезает. Если общая и жилая площади почти дублируют друг друга, веса могут меняться в противоположных направлениях при почти постоянном прогнозе. Это объясняет отличие «прогноз уже стабилен» от «коэффициенты точно определены».

Средние и масштабы оценивают только на train. Для $z_j=(x_j-m_j)/s_j$ и модели $b_z+\Sigma w_z,_j z_j$ возвращение к исходным единицам даёт $w_x,_j=w_z,_j/s_j$ и $b_x=b_z-\Sigma w_z,_j m_j/s_j$. Постоянный признак с $s_j=0$ нельзя делить на стандартное отклонение.

15 / BATCH И SGD

Число шагов и число просмотренных объектов

$$g_t=\frac{1}{m}\sum_{i\in B_t}\nabla\ell_i(\beta_t),\qquad \beta_{t+1}=\beta_t-\eta_t g_t$$

Full batch использует все n строк, SGD - одну, mini-batch - m строк. Если каждый индекс выбирается равномерно независимо от прошлых шагов, условное ожидание g_t равно полному градиенту. За одну эпоху просматривают n объектов; шаг - одно обновление. Поэтому 100 шагов разных алгоритмов не означают одинаковый объём работы.

При постоянном η шум SGD обычно не позволяет весам буквально остановиться. Для сходимости к точному минимуму нужны дополнительные условия; типичные условия на шаги - $\Sigma\eta_t=\infty$ и $\Sigma\eta_t^2<\infty$ вместе с контролем дисперсии стохастических градиентов и устойчивостью итераций. В интерактивном модуле используется полный градиент, поэтому движение детерминировано при фиксированных данных и параметрах.

16 / УСЛОВНОЕ СРЕДНЕЕ

Случайный шум не обязан быть нормальным

Пусть $Y=m(U)+\varepsilon$, где $m(u)=E[Y|U=u]$, а $E[Y^2]<\infty$. Тогда $E[\varepsilon|U]=0$ по определению. Признаки могут быть случайными; при обучении мы наблюдаем одну их реализацию.

Почему MSE ищет именно условное среднее

1 $$Y - g(U) = \varepsilon + m(U) - g(U)$$

Добавляем и вычитаем условное среднее для любой функции прогноза g с конечным риском.

2 $$\mathbb{E}[(Y - g(U))^2 \mid U] = \mathbb{E}[\varepsilon^2 \mid U] + (m(U) - g(U))^2 \\ +2(m(U) - g(U))\mathbb{E}[\varepsilon \mid U]$$

При фиксированном U функция m(U)−g(U) - константа.

3 $$\mathbb{E}[(Y - g(U))^2 \mid U] = \mathbf{Var}(Y \mid U) + (m(U) - g(U))^2$$

Перекрёстное слагаемое равно нулю.

4 $$\arg\min_g \mathbb{E}[(Y - g(U))^2] = m(U) \quad \text{почти наверное}$$

Остаётся минимизировать неотрицательный квадрат; нормальность нигде не использовалась.

Если ограничиться прямыми, найдём лучшую линейную аппроксимацию m(U). Она совпадёт с m(U) только когда условное среднее линейно. Даже идеально сошедшийся градиентный спуск не исправляет ошибочный класс функций.

> **Среднее шума и распределение - разные предположения.** E[ε|X]=0 достаточно для несмещённости МНК при полном ранге. Постоянная дисперсия и некоррелированность нужны для классической формулы дисперсии. Нормальность добавляет точные распределения оценок и статистик на конечной выборке.

17 / НОРМАЛЬНЫЙ ШУМ → MSE

Вывод максимального правдоподобия

Предположим совместно, условно на X: ε~N(0,σ²I), σ²>0. Это означает независимые нормальные ошибки с одной дисперсией. Признаки и сами ответы в совокупности нормальными быть не обязаны.

От плотности к оптимизации

1 $$p(y \mid X, \beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|y - X\beta\|^2}{2\sigma^2}\right)$$

Совместная плотность - произведение n условных нормальных плотностей. Это плотность, а не вероятность отдельного точного значения y.

2

$$-\log p = \frac{n}{2}\log(2\pi\sigma^2) + \frac{\mathrm{SSE}(\beta)}{2\sigma^2}$$

Логарифм переводит произведение в сумму.

3

$$\arg\min_{\beta}(-\log p) = \arg\min_{\beta}\mathrm{SSE}(\beta) = \widehat{\beta}_{\mathrm{OLS}}$$

При фиксированной положительной дисперсии добавки и множитель не влияют на оптимальные веса.

4

$$\frac{\partial(-\log p)}{\partial v} = \frac{n}{2v} - \frac{\mathrm{SSE}}{2v^2} = 0, \qquad v = \sigma^2$$

Если дисперсия неизвестна, её тоже можно оценить.

5

$$\widehat{\sigma}^2_{\mathrm{MLE}} = \frac{\mathrm{SSE}(\widehat{\beta})}{n}$$

При SSE>0 это оптимум по v>0. Несмещённая оценка будет другой: SSE/(n−p).

Если SSE=0, правдоподобие неограниченно растёт при σ²→0: конечной совместной MLE с положительной дисперсией нет. В частности, этот случай возможен при интерполяции. ЦПТ иногда мотивирует приближённую нормальность суммы многих малых влияний, но не доказывает её для любого шума.

Продолжить чтение: Яндекс Учебник - вероятностный подход в ML ↗

18 / ДРУГИЕ РАСПРЕДЕЛЕНИЯ ШУМА

Выбор плотности меняет функцию потерь

Для независимых ошибок с известной общей плотностью q и фиксированными её параметрами масштаба условное отрицательное лог-правдоподобие равно $\Sigma_i - \log q(e_i)$, где $e_i = y_i - x_i^T\beta$. Отсюда можно вывести loss для конкретной гипотезы о шуме.

Связь распределения шума с обучением

Нормальный	
Плотность $q(e) \propto \exp\left(-\frac{e^2}{2\sigma^2}\right)$	Отрицательный log-loss, без константы $\frac{e^2}{2\sigma^2}$
МНК; квадратичный рост штрафа.	

Лаплас, масштаб c>0

Плотность

$$q(e) = \frac{\exp(-|e|/c)}{2c}$$

Отрицательный log-loss, без константы

$$\frac{|e|}{c}$$

MAE; в точечной задаче оптимальна условная медиана.

Стьюдент, v>0, масштаб s>0

Плотность

$$q(e) \propto \left(1 + \frac{e^2}{\nu s^2}\right)^{-(\nu+1)/2}$$

Отрицательный log-loss, без константы

$$\frac{\nu+1}{2} \log\left(1 + \frac{e^2}{\nu s^2}\right)$$

Более медленный рост в хвостах; оптимизация в общем случае невыпуклая.

Коши, масштаб c>0

Плотность

$$q(e) = \frac{1}{\pi c[1 + (e/c)^2]}$$

Отрицательный log-loss, без константы

$$\log\left(1 + (e/c)^2\right)$$

Случай v=1; нет среднего и дисперсии, обычные аргументы про MSE-риск неприменимы.

Равномерный на [−c,c]

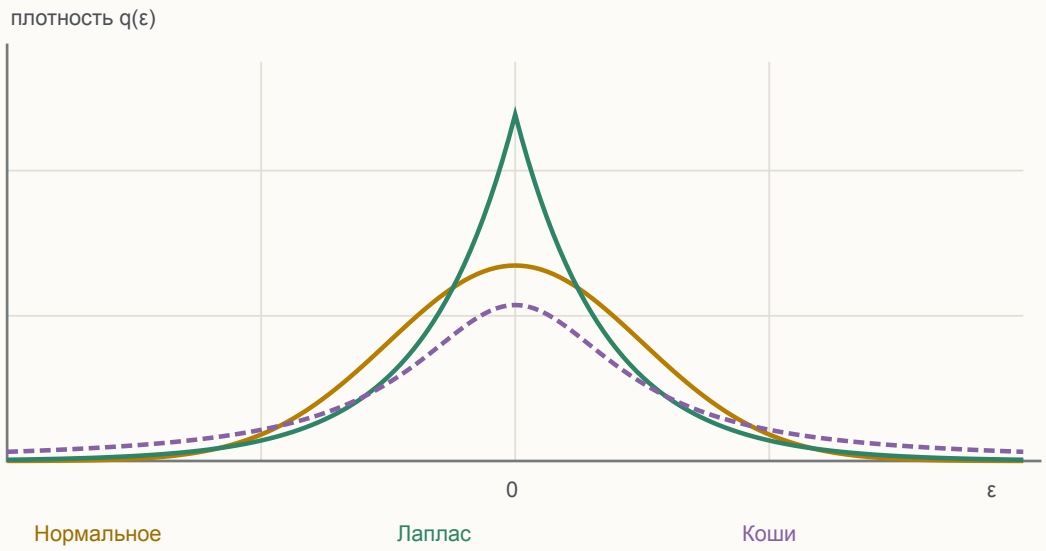
Плотность

$$q(e) = \begin{cases} \frac{1}{2c}, & |e| \le c, \\ 0, & |e| > c \end{cases}$$

Отрицательный log-loss, без константы

$$\begin{cases} \text{const}, & |e| \le c, \\ +\infty, & |e| > c \end{cases}$$

При известном c любые допустимые веса одинаково правдоподобны.



Нормальное N(0,1) и Лаплас с масштабом 1/√2 имеют дисперсию 1. У Коши с масштабом 1 дисперсии и математического ожидания нет; его хвост убывает как 1/ε². Кривые вычислены по плотностям, а не нарисованы произвольно.

У Лапласа конечная дисперсия $2c^2$. Поэтому МНК при нулевом условном среднем всё ещё несмещён, хотя уже не совпадает с MLE. У Стьюдента среднее существует при $\nu>1$, дисперсия - при $\nu>2$. Симметрия плотности сама по себе не гарантирует существование математического ожидания.

Если у равномерного шума неизвестен масштаб, его MLE при фиксированных весах равен $\max_i|e_i|$. Подстановка даёт минимизацию максимального абсолютного остатка, а не суммы квадратов. При точной интерполяции снова возникает вырождение масштаба к нулю.

Асимметричный шум с конечным средним можно центрировать, но центр расположения, медиана и среднее вообще различны. Например, $\varepsilon=Z-1$ для $Z\sim\mathrm{Exp}(1)$ имеет среднее 0, но медиану $\log 2-1$. MSE и MAE тогда решают разные задачи даже при бесконечном числе данных.

> Распределение шума описывает отклонения ответов при фиксированных признаках. Гистограмма самого таргета этого не показывает. А нормальность обученных остатков нельзя автоматически приравнять к независимости истинных ошибок.

19 / НЕСМЕЩЁННОСТЬ И ДИСПЕРСИЯ

Насколько случайны найденные коэффициенты

Предположим $y=X\beta_*+\varepsilon$, $\mathrm{rank}(X)=p$, $E[\varepsilon|X]=0$ и конечную $\Omega=\mathrm{Cov}(\varepsilon|X)$. Положим $A=(X^TX)^{-1}X^T$, поэтому $AX=I$.

Два свойства линейной оценки

1 $$\widehat{\beta} = Ay = AX\beta_0 + A\varepsilon = \beta_0 + A\varepsilon$$

Вся случайность весов выражена через линейное преобразование шума.

2 $$\mathbb{E}[\widehat{\beta} \mid X] = \beta_0 + A\mathbb{E}[\varepsilon \mid X] = \beta_0$$

Это условная несмещённость. При существовании безусловного ожидания она даёт и E[β]=β₀.

3 $$\mathrm{Cov}(\widehat{\beta} \mid X) = A\Omega A^{\top}$$

Для постоянной при фиксированном X матрицы A ковариация преобразуется слева и справа.

4 $$\Omega = \sigma^2 I \quad \Longrightarrow \quad \mathrm{Cov}(\widehat{\beta} \mid X) = \sigma^2 (X^{\top}X)^{-1}$$

Используем $AA^{\top}=(X^{\top}X)^{-1}$. Нормальность не требовалась.

$$\mathrm{Var}(\widehat{a} \mid x) = \frac{\sigma^2}{S_{xx}},$$
$$\mathrm{Var}(\hat{b} \mid x) = \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}} \right),$$
$$\mathrm{Cov}(\widehat{a}, \hat{b} \mid x) = -\frac{\sigma^2 \overline{x}}{S_{xx}}$$

Одномерный случай: $\hat{a}-a_0=\Sigma(x_i-\bar{x})\varepsilon_i/S_{xx}$, $\hat{b}-b_0=\bar{\varepsilon}-\bar{x}(\hat{a}-a_0)$. Из $\Sigma(x_i-\bar{x})=0$ следует $\mathrm{Cov}(\bar{\varepsilon},\hat{a})=0$; подстановка даёт все три формулы.

Больший разброс x помогает оценить наклон точнее при том же шуме. Малое S_{xx} делает оценку неустойчивой. «Несмещённая» означает правильную в среднем по повторным выборкам, а не точную в каждом конкретном наборе.

20 / ТЕОРЕМА ГАУССА-МАРКОВА

В каком смысле МНК оптимален

При полном ранге, E[ε|X]=0 и Cov(ε|X)=σ²I МНК имеет наименьшую условную дисперсию среди всех оценок, *линейных по y* и несмещённых для любого β₀. Это свойство BLUE. Нормальность не нужна.

Доказательство через произвольного конкурента

1 $$\widetilde{\beta} = Cy, \qquad \mathbb{E}[\widetilde{\beta} \mid X] = CX\beta_0$$

C может зависеть от X, но не от ответов y.

2

$$\mathbb{E}[\widetilde{\beta} \mid X] = \beta_0 \ \ (\forall \beta_0) \quad \Longleftrightarrow \quad CX = I$$

Несмещённость накладывает матричное ограничение.

3

$$C = A + D, \qquad A = (X^\top X)^{-1} X^\top \quad \Longrightarrow \quad DX = 0$$

Отделяем МНК-часть от произвольного отличия.

4

$$AD^\top = (X^\top X)^{-1} X^\top D^\top = (X^\top X)^{-1} (DX)^\top = 0$$

Перекрёстные члены ковариации исчезают.

5

$$\operatorname{Cov}(\widetilde{\beta} \mid X) - \operatorname{Cov}(\widehat{\beta} \mid X) = \sigma^2 DD^\top$$

Раскрываем σ²(A+D)(A+D)ᵀ.

6

$$v^\top [\operatorname{Cov}(\widetilde{\beta} \mid X) - \operatorname{Cov}(\widehat{\beta} \mid X)] v = \sigma^2 \| D^\top v \|^2 \geq 0$$

Ни одна линейная комбинация коэффициентов не оценивается конкурентом с меньшей дисперсией.

Теорема не утверждает оптимальность среди всех возможных процедур и не запрещает ridge иметь меньшую среднеквадратичную ошибку: ridge допускает смещение. При гетероскедастичности предпосылка σ²I нарушается и этот вывод уже не следует.

Продолжить чтение: О. А. Демидова, НИУ ВШЭ - классическая линейная регрессия ↗

21 / ДИСПЕРСИЯ И ИНТЕРВАЛЫ

От остатков к статистической неопределённости

Пусть n>p и выполнены условия предыдущего раздела. Остаток e=(I−P)ε; матрица M=I−P симметрична, идемпотентна и имеет ранг n−p.

Почему делим на n−p

1

$$\mathrm{SSE} = e^\top e = \varepsilon^\top M \varepsilon$$

Используем M²=M и MX=0.

2

$$\mathbb{E}[\varepsilon^\top M \varepsilon \mid X] = \sum_i \sum_j M_{ij} \mathbb{E}[\varepsilon_i \varepsilon_j \mid X] = \sigma^2 \operatorname{tr}(M)$$

При нулевом среднем и Ω=σ²I остаются диагональные слагаемые.

3

$$\operatorname{tr}(M) = n - p \quad \Longrightarrow \quad \mathbb{E}[\mathrm{SSE} \mid X] = (n-p)\sigma^2$$

У P ровно p собственных значений 1; у M=I−P единиц уже n−p, остальные значения равны 0.

4

$$s^2 = \frac{\mathrm{SSE}}{n-p} \quad \Longrightarrow \quad \mathbb{E}[s^2 \mid X] = \sigma^2$$

p оценённых параметров использовали p степеней свободы. MSE=SSE/n смещена вниз как оценка σ².

Добавим нормальность ε|X~N(0,σ²I). Тогда β̂|X~N(β₀,σ²(XᵀX)⁻¹). После ортогонального поворота SSE/σ² - сумма квадратов n−p независимых стандартных нормальных величин, то есть χ² с n−p степенями свободы.

От нормального числителя к t-статистике

1

$$\mathrm{Cov}(A\varepsilon, M\varepsilon \mid X) = \sigma^2 AM = 0$$

AM=0. Совместно нормальные векторы с нулевой ковариацией независимы, поэтому β̂ независимо от s².

2

$$Z_j = \frac{\widehat{\beta}_j - \beta_{0,j}}{\sigma\sqrt{[(X^\top X)^{-1}]_{jj}}} \sim \mathcal{N}(0,1)$$

Стандартизуем одну координату.

3

$$T_j = \frac{Z_j}{\sqrt{(\mathrm{SSE}/\sigma^2)/(n-p)}} \sim t_{n-p}$$

Независимое отношение нормальной величины к корню из нормированной χ² имеет распределение Стьюдента.

4

$$\widehat{\beta}_j \pm t_{1-\alpha/2,n-p}\, s\sqrt{[(X^\top X)^{-1}]_{jj}}$$

Инверсия |T ⱼ |≤квантиль даёт доверительный интервал уровня 1−α.

95% относится к доле интервалов, покрывающих фиксированный истинный параметр в повторных выборках, а не к вероятности фиксированного параметра в уже вычисленном частотном интервале. Проверка H₀:β ⱼ =c использует |(β̂ⱼ −c)/SE ⱼ | и ту же t-квантиль. Статистическая значимость не означает большой эффект или причинность.

Без нормального шума эти t-интервалы в общем случае не точны на малой выборке. Асимптотические интервалы требуют условий ЦПТ и подходящей оценки ковариации. При n≤p формула s² с n−p неприменима.

22 / СРЕДНЕЕ И НОВЫЙ ОТВЕТ

Почему предиктивный интервал шире

Пусть x_0 - новый столбец из p признаков, включая единицу, $\mu_0=x_0^T\beta_0$ и $\hat{\mu_0}=x_0^T\hat{\beta}$. При той же нормальной модели и независимом новом шуме ε_0 дисперсии равны:

$$\mathbf{Var}(\widehat{\mu}_0 - \mu_0 \mid X, x_0) = \sigma^2 h_0, \quad h_0 = x_0^\top (X^\top X)^{-1} x_0,$$
$$\mathbf{Var}(Y_0 - \widehat{\mu}_0 \mid X, x_0) = \sigma^2 (1 + h_0)$$

$Y_0=\mu_0+\varepsilon_0$: добавляется дисперсия нового независимого шума σ^2.

$$\text{Среднее:} \quad \widehat{\mu}_0 \pm t_{1-\alpha/2,n-p}\, s\sqrt{h_0},$$
$$\text{Новый ответ:} \quad \widehat{\mu}_0 \pm t_{1-\alpha/2,n-p}\, s\sqrt{1+h_0}$$

В одномерном случае $h_0=1/n+(x_0-\bar{x})^2/S_{xx}$. В примере из четырёх точек $s^2=1.8/2=0.9$. При $x_0=2.5$ получаем $h_0=0.25$ и $\hat{\mu_0}=3.5$. С $t_{0.975,2}\approx4.303$ интервал среднего примерно [1.46,5.54], а нового ответа - [−1.06,8.06]. Четыре точки дают мало точности.

Дальше от $\bar{x}$ оба интервала шире. Но они описывают неопределённость *внутри принятой модели*. Если за пределами train зависимость меняется, даже широкий гауссовский интервал может оказаться самоуверенным. Отрицательная нижняя граница для неотрицательного ответа может сигнализировать о неуместной модели, а не о необходимости молча обрезать интервал.

23 / НЕОДИНАКОВЫЙ И ЗАВИСИМЫЙ ШУМ

Взвешивание и корректные стандартные ошибки

При $\Omega\neq\sigma^2 I$ оценка $\hat{\beta}$ остаётся несмещённой, если $E[\varepsilon|X]=0$. Но классическая ковариация неверна: нужна $(X^TX)^{-1}X^T\Omega X(X^TX)^{-1}$. Ω может иметь разные дисперсии на диагонали и ненулевые ковариации между строками.

Обобщённый МНК при известной $\Omega>0$

1 $$Q(\beta) = (y - X\beta)^\top \Omega^{-1} (y - X\beta)$$

Штрафуем остатки с учётом их масштаба и зависимости.

2 $$dQ = -2(y - X\beta)^\top \Omega^{-1} X\, d\beta$$

Ω^{-1} симметрична и не зависит от β.

3

$$\widehat{\beta}_{\mathrm{GLS}} = (X^\top \Omega^{-1} X)^{-1} X^\top \Omega^{-1} y$$

При полном столбцовом ранге $X^\top\Omega^{-1}X$ положительно определена.

4

$$X^* = \Omega^{-1/2} X, \quad y^* = \Omega^{-1/2} y, \quad \mathrm{Cov}(\varepsilon^* \mid X) = I$$

После «отбеливания» это обычный МНК; применяем теорему Гаусса-Маркова.

5

$$\mathrm{Cov}(\widehat{\beta}_{\mathrm{GLS}} \mid X) = (X^\top \Omega^{-1} X)^{-1}$$

Линейное преобразование шума даёт ковариацию оценки.

Если $\Omega=\mathrm{diag}(\sigma_i^2)$, получаем взвешенный МНК: $\Sigma e_i^2/\sigma_i^2$. Менее шумное наблюдение получает больший вес. Формулы остаются теми же, если Ω известна с точностью до общего положительного множителя.

$$\widehat{V}_{\mathrm{HC0}} = (X^\top X)^{-1} X^\top \,\mathrm{diag}(e_i^2) X (X^\top X)^{-1}$$

Робастная к гетероскедастичности оценка ковариации: меняет стандартные ошибки, но не веса МНК.

HC0 - асимптотическая оценка, не точная гарантия для любых четырёх строк. Ей нужны независимые наблюдения, подходящие моменты и отсутствие доминирующих точек при росте n. Для временной зависимости нужны HAC-оценки, для групповой - кластерные. Подставлять e_i^2 в HC0 при зависимых строках недостаточно.

24 / СОСТОЯТЕЛЬНОСТЬ И СМЕЩЕНИЕ

Чего не исправит большая выборка

Когда МНК приближается к истинным весам

1

$$\widehat{\beta} - \beta_0 = (X^\top X/n)^{-1} (X^\top \varepsilon/n)$$

Переписываем ошибку оценки в виде двух средних по наблюдениям.

2

$$X^\top X/n \xrightarrow{P} Q \succ 0, \qquad X^\top \varepsilon/n \xrightarrow{P} 0$$

Это достаточные условия: например, i.i.d. строки, конечные вторые моменты и $E[x_i\varepsilon_i]=0$ с невырожденным $E[x_i x_i^T]$.

3

$$\widehat{\beta} \xrightarrow{P} \beta_0$$

Обращение непрерывно около невырожденной Q; произведение сходится к нулю.

Несмещённость - свойство среднего на конечной выборке; состоятельность - предел при n→∞. Они не заменяют друг друга. При E[xε]≠0 предел будет β₀+Q⁻¹E[xε]: больше данных делает неверный коэффициент всё точнее.

$$Y = a_0 U + \gamma Z + b_0 + \varepsilon, \quad \operatorname{Cov}(U, \varepsilon) = 0,$$

$$\text{без признака } Z: \quad a^* = a_0 + \gamma \frac{\operatorname{Cov}(U, Z)}{\operatorname{Var}(U)}$$

Один коррелированный пропущенный фактор достаточно меняет наклон. Это точный вывод из ковариационной формулы.

Ошибка измерения признака тоже важна: если наблюдаем W=U+δ, где δ имеет нулевое среднее и независима от U и ε, то регрессия Y=a₀U+b₀+ε на W имеет наклон a₀Var(U)/(Var(U)+Var(δ)). Он сжат к нулю. Обычная регуляризация и дополнительные итерации это смещение не устраняют.

25 / RIDGE: ТОЧНАЯ ФОРМУЛА

Добавляем штраф, сохраняя свободный член

В модуле регуляризуются веса признаков, а смещение b - нет. Для общей β=(b,w^T)^T введём D=diag(0,1,…,1).

Матричный вывод ridge

1 $$J_\lambda(\beta) = \frac{1}{n}\|X\beta - y\|^2 + \lambda \beta^\top D \beta, \qquad \lambda \geq 0$$

Это MSE плюс λΣw$_j$².

2 $$\nabla J_\lambda = \frac{2}{n} X^\top (X\beta - y) + 2\lambda D\beta$$

Штраф добавляет производную только по весам.

3 $$(X^\top X + n\lambda D)\widehat{\beta}_\lambda = X^\top y$$

Множитель n возникает из выбранного усреднения MSE.

4 $$\widehat{\beta}_\lambda = (X^\top X + n\lambda D)^{-1} X^\top y \qquad (\lambda > 0)$$

h^T(X^{T}X+nλD)h=‖Xh‖²+nλΣh$_j$²: ноль вынуждает все веса h быть нулём, затем столбец единиц вынуждает нулевое смещение. Для непустой выборки матрица обратима.

После центрирования X_c=X₀−1x̄^{T} и y_c=y−ȳ1 можно решить ŵλ=(X_c^{T}X_c+nλI)⁻¹X_c^{T}y_c, затем b̂λ=ȳ−x̄^{T}ŵλ. Так видно, почему штраф не тянет средний прогноз к нулю.

За устойчивость платим смещением

Рассмотрим центрированную задачу для весов, A=X_c^{T}X_c, k=nλ>0. Условно на дизайн предполагаем E[ε]=0, Cov(ε)=σ²I до центрирования; в произведении X_c^{T}ε центрирование шума ничего не меняет.

$$\mathbb{E}[\widehat{w}_\lambda \mid X] - w_0 = -k(A + kI)^{-1} w_0,$$
$$\operatorname{Cov}(\widehat{w}_\lambda \mid X) = \sigma^2 (A + kI)^{-1} A (A + kI)^{-1}$$

Первая формула получается из E[ŵλ]=(A+kI)$^{-1}$Aw₀ и равенства A=(A+kI)−kI. Вторая - из правила Cov(Bε)=B Cov(ε) B^T.

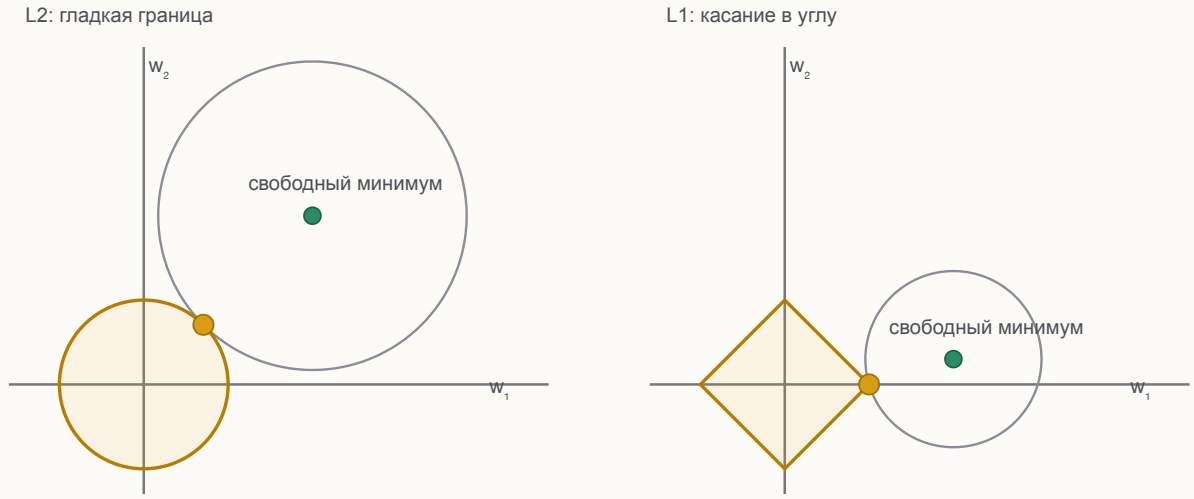
$$d_j > 0: \quad \text{bias}_j = -\frac{k\theta_j}{d_j + k}, \quad \text{variance}_j = \frac{\sigma^2 d_j}{(d_j + k)^2},$$
$$\text{MSE}_j = \frac{k^2\theta_j^2 + \sigma^2 d_j}{(d_j + k)^2}$$

θ_j - истинный коэффициент в этом собственном направлении. У МНК $\text{variance}_j = \sigma^2/d_j$ и $\text{bias}_j = 0$.

При $d_j \approx 0$ дисперсия МНК огромна, а ridge её уменьшает. При большом истинном θ_j слишком сильный штраф даёт заметный bias. Поэтому универсального λ для всех задач нет. В сингулярном направлении $d_j = 0$ данных для оценки θ_j нет: ridge выбирает ноль, а не «восстанавливает истину».

При SVD X_c=UΣV^T весовой множитель меняется с $1/s_j$ у МНК на $s_j/(s_j^2+n\lambda)$ у ridge. Это делает наглядной связь между регуляризацией, шумом и маленькими сингулярными значениями.

Почему L1 может дать ровно нулевой вес



Частный случай квадратичной ошибки с круговыми линиями уровня. Жёлтая граница - допустимые веса; зелёная точка - минимум без ограничения. На L2 оптимум имеет две ненулевые координаты. На L1 в показанном примере $w_2=0$. Это иллюстрация; общее обоснование разреженности даёт субградиент ниже.

Условие оптимума Lasso

1 $$\min_w \left[J(w) + \lambda \sum_j |w_j| \right]$$

В центрированной задаче свободный член восстанавливается отдельно.

2 $$\partial |w_j| = \{\operatorname{sign}(w_j)\}\ (w_j \neq 0), \qquad \partial |0| = [-1, 1]$$

В нуле модуль имеет целый интервал субградиентов.

3 $$0 \in \partial_j J + \lambda \partial |w_j|$$

Для выпуклой функции это необходимое и достаточное условие оптимума по координате при остальных зафиксированных.

4 $$w_j = 0 \text{ допустим в оптимуме} \iff |\partial_j J| \leq \lambda$$

L1 может уравновесить ненулевой градиент ошибки прямо в нуле. У гладкого L2 такого интервала нет.

Если $X_c^TX_c/n=I$ и $c=X_c^Ty_c/n$, то $J(w)=\Sigma_j (w_j - c_j)^2+\text{const}$. Условие выше даёт $\hat{w}_j = \text{sign}(c_j)\max(|c_j| - \lambda/2, 0)$. Порог именно $\lambda/2$ из-за MSE без множителя 1/2. При коррелированных столбцах покоординатной независимости уже нет.

Вывод мягкого порога для одной координаты

1 $$w_j > 0: \quad 2(w_j - c_j) + \lambda = 0 \quad \Longrightarrow \quad w_j = c_j - \lambda/2$$

Эта ветвь согласована со знаком w_j только при $c_j > \lambda/2$.

2 $$w_j < 0: \quad 2(w_j - c_j) - \lambda = 0 \quad \Longrightarrow \quad w_j = c_j + \lambda/2$$

Отрицательная ветвь требует $c_j < -\lambda/2$.

3 $$w_j = 0: \quad 0 \in -2c_j + \lambda[-1, 1] \quad \Longleftrightarrow \quad |c_j| \le \lambda/2$$

Когда ни одна ненулевая ветвь не допустима, интервал субградиентов содержит ноль. Это три случая одной формулы soft-thresholding.

L1 часто выбирает один из коррелированных признаков, но это не доказывает его причинную важность. Штрафы зависят от единиц измерения; масштабирование перед ridge/lasso должно быть осмысленным.

28 / БАЙЕСОВСКИЙ ВЗГЛЯД

MAP и распределение весов после данных

Рассмотрим модель $y|\beta, X \sim N(X\beta, \sigma^2 I)$ с известной σ^2 и собственным нормальным prior $\beta \sim N(m_0, V_0)$, $V_0 > 0$. Prior описывает неопределённость параметров до выборки.

Дополняем квадрат в апостериорной плотности

1 $$-2 \log p(\beta \mid X, y) = \frac{\|y - X\beta\|^2}{\sigma^2} + (\beta - m_0)^\top V_0^{-1} (\beta - m_0) + \text{const}$$

Формула Байеса: posterior пропорционален likelihood × prior.

2 $$V_n^{-1} = \frac{X^\top X}{\sigma^2} + V_0^{-1}, \qquad h = \frac{X^\top y}{\sigma^2} + V_0^{-1} m_0$$

После раскрытия скобок квадратичная часть равна $\beta^\top V_n^{-1} \beta - 2\beta^\top h$.

3 $$m_n = V_n h,$$
$$\beta^\top V_n^{-1} \beta - 2\beta^\top h = (\beta - m_n)^\top V_n^{-1} (\beta - m_n) + \text{const}$$

Дополнение квадрата показывает и центр, и кривизну плотности.

4 $$\beta \mid X, y \sim \mathcal{N}(m_n, V_n), \qquad \widehat{\beta}_{\text{MAP}} = \mathbb{E}[\beta \mid X, y] = m_n$$

Для этой нормальной модели мода совпадает со средним; в общем случае это неверно.

5

$$Y_0 \mid x_0, X, y \sim \mathcal{N}(x_0^\top m_n, \sigma^2 + x_0^\top V_n x_0)$$

Интегрируем неопределённость весов и добавляем независимый шум нового ответа.

$$w \sim \mathcal{N}(0, \tau^2 I) \quad \Longrightarrow \quad \lambda_{\text{MSE}} = \frac{\sigma^2}{n\tau^2}$$

Умножаем отрицательное log-posterior на 2σ²/n. Для loss=SSE вместо MSE коэффициент штрафа был бы σ²/τ².

Чтобы получить ridge из модуля без штрафа на b, используем нормальный prior только на w и плоский prior на b. Плоская плотность на всей прямой не нормируется, поэтому это несобственный prior, а не подстановка в $V_0 \to 0$. Для непустой выборки posterior остаётся собственным благодаря столбцу единиц и штрафу на все веса.

Лапласовский prior на w даёт L1-штраф. Не путай его с лапласовским *шумом*: первый меняет регуляризацию, второй - loss на данных. Байесовский интервал имеет вероятностный смысл относительно posterior; его корректность зависит в том числе от prior и модели данных.

Продолжить чтение: Яндекс Учебник - байесовский подход к оцениванию ↗

29 / РАЗЛОЖЕНИЕ ОШИБКИ ПРОГНОЗА

Доказательство bias² + variance + noise

Зафиксируем новый x. Пусть f(x)=E[Y|x], σ²(x)=Var(Y|x), обучающая выборка D независима от нового ответа, а все следующие вторые моменты конечны. Обозначим m=E_D[f_D(x)].

Раскрываем квадрат и проверяем смешанные члены

1

$$\widehat{f}_D(x) - Y = (\widehat{f}_D(x) - m) + (m - f(x)) - \varepsilon$$

Три слагаемых: разброс обученной модели, систематическое отклонение и шум нового ответа.

2

$$\mathbb{E}_D[\widehat{f}_D - m] = 0, \qquad \mathbb{E}[\varepsilon \mid x] = 0$$

Средние двух случайных слагаемых равны нулю.

3

$$\mathbb{E}[(\widehat{f}_D - m)\varepsilon \mid x] = 0$$

Новый шум независим от обучения и имеет нулевое условное среднее. Остальные смешанные члены тоже обнуляются.

4

$$\mathbb{E}_{D,Y|x}[(\widehat{f}_D(x) - Y)^2] = (m - f(x))^2 + \mathrm{Var}_D(\widehat{f}_D(x)) + \sigma^2(x)$$

Остаются ровно три квадратичных вклада.

Это точное равенство при заданных условиях. Слагаемое noise нельзя уменьшить настройкой весов при фиксированном наборе информации. Можно изменить саму постановку: измерить дополнительные полезные признаки или улучшить качество измерений. Регуляризация действует на первые два слагаемых, а не удаляет шум из мира.

30 / НЕЛИНЕЙНОСТЬ И НОВЫЕ ПРИЗНАКИ

Когда прямая - слишком узкая гипотеза

В примере $Y=U^2$ прямая не находит зависимость из-за нулевой ковариации. Добавим $\varphi(U)=(U,U^2)$ - и модель $b+w_1U+w_2U^2$ включает правильную функцию. Матрица X меняется, но доказательства МНК сохраняются: параметры всё ещё входят линейно.

Полиномы высокого порядка часто имеют почти зависимые столбцы и легко переобучаются. Степень, преобразования и λ выбирают на validation. Категориальные признаки кодируют индикаторами; вместе со свободным членом полный one-hot для одной категории даёт точную зависимость столбцов, поэтому обычно убирают одну базовую категорию.

Нельзя из низкого train-MSE заключить, что получилась адекватная модель. При расширении пространства признаков МНК может только уменьшить train-SSE: старое решение остаётся допустимым с нулевыми новыми весами. Это алгебраическое свойство, а не доказательство обобщения.

31 / ДРУГИЕ LOSS И МЕТРИКИ

Среднее, медиана и квантиль отвечают на разные вопросы

Мы доказали оптимальность условного среднего для квадрата. Для абсолютной ошибки при $E[|Y||x] <\infty$ и непрерывной условной функции распределения F_x производная $E[|Y-c||x]$ по c равна $2F_x(c) -1$. Ноль получается на медиане. При атомах вместо производной используют субградиент, и медиана может быть не единственной.

От модуля к условной медиане

1 $$\frac{\partial |y-c|}{\partial c} = \begin{cases} 1, & y < c, \\ -1, & y > c \end{cases}$$

Разбираем две линейные ветви модуля. Точка y=c имеет нулевую вероятность при непрерывном распределении.

2 $$\frac{\partial \mathbb{E}[|Y-c| \mid x]}{\partial c} = P(Y < c \mid x) - P(Y > c \mid x)$$

Разностные отношения модуля ограничены по абсолютной величине единицей. Теорема о мажорируемой сходимости разрешает перенести предел под ожидание.

3

$$P(Y < c \mid x) - P(Y > c \mid x) = F_x(c) - (1 - F_x(c)) = 2F_x(c) - 1$$

В нуле производной F_x(c)=1/2. Выпуклость абсолютной ошибки доказывает, что это глобальный минимум.

$$\rho_q(e) = e(q - \mathbf{1}[e < 0]), \qquad e = y - \hat{y}, \quad q \in (0,1),$$
$$\frac{\partial \mathbb{E}[\rho_q(Y - c) \mid x]}{\partial c} = F_x(c) - q$$

При непрерывности оптимум - условная q-квантиль. Знак остатка важен: если взять ŷ−y, формулу нужно изменить.

У квантильной ошибки производная по c равна 1−q при y<c и −q при y>c. Поэтому её ожидание равно (1−q)F_x(c)−q(1−F_x(c))=F_x(c)−q. Производная ограничена, так что тот же перенос предела под ожидание допустим. При атомах условие оптимума записывается F_x(c−)≤q≤F_x(c).

RMSE=√MSE возвращает ошибку в единицы ответа и при отсутствии дополнительного штрафа имеет тот же минимум. С регуляризацией √MSE+λ‖w‖² и MSE+λ‖w‖² - разные задачи. MAE меньше реагирует на выбросы ответа, но не защищает автоматически от экстремальных признаков.

Huber loss равна e²/2 при |e|≤δ и δ(|e|−δ/2) иначе: возле нуля квадратична, в хвостах линейна. MAPE нестабильна около нулевого таргета. Метрику выбирают по цене ошибки, а не только по удобству производной.

32 / ПРОВЕРКА НА НОВЫХ ДАННЫХ

От доказанного минимума к полезному прогнозу

Оптимизация доказывает минимальность train-loss внутри класса, но не качество на будущих данных. Разделяй train для весов, validation для выбора признаков, λ и stopping rule, test для окончательной проверки. Если многократно выбирать по test, он перестаёт быть независимой оценкой.

Для временных данных разделение должно соблюдать время. Если строки относятся к одному человеку или устройству, их часто нужно разделять группами. Нормализация, заполнение пропусков и выбор признаков обучаются только внутри train, в том числе внутри каждого CV-фолда.

33 / ЧТО ОЦЕНИВАЕТ VALIDATION

Риск - ожидание по будущим объектам

$$R(f) = \mathbb{E}_{(U,Y)\sim P}[(Y - f(U))^2],$$
$$\widehat{R}_{\text{val}}(f) = \frac{1}{m}\sum_{i=1}^{m}(y_i - f(u_i))^2$$

Для фиксированной модели, независимой от validation, и i.i.d. validation из P с конечным риском E[R̂_val|f]=R(f). Это обоснование оценки. Но после выбора победителя среди многих моделей по этой же выборке результат становится оптимистичным: победил в том числе шум оценки.

Если будущее распределение меняется, прежнее ожидание относится уже к другому P. Ни теорема Гаусса-Маркова, ни малая норма градиента не дают защиты от такого сдвига.

34 / ОСТАТКИ И ОГРАНИЧЕНИЯ

Что смотреть после обучения

Диагностика гипотез, а не автоматические диагнозы

Наблюдение	Что проверить
Изгиб на графике e против ŷ	Возможна нелинейная форма условного среднего; проверить преобразования признаков.
Разброс остатков растёт	Возможна гетероскедастичность; классические SE могут быть неверными.
Ошибки идут сериями во времени	Возможна зависимость наблюдений; проверить временной split и ковариацию.
Одна точка сильно меняет веса	Проверить выброс ответа и leverage - необычный вектор признаков.
Веса скачут, прогноз почти тот же	Проверить ранг и маленькие сингулярные значения.

$$e = (I - P)\varepsilon \quad\Longrightarrow\quad \operatorname{Cov}(e \mid X) = \sigma^2(I - P),$$
$$\operatorname{Var}(e_i \mid X) = \sigma^2(1 - P_{ii})$$

Даже при независимом одинаково распределённом шуме обученные остатки обычно зависимы и имеют разные дисперсии.

Диагональ P_{ii} называется leverage: она зависит от геометрии признаков. Большая leverage позволяет точке притянуть прогноз к себе и получить маленький остаток. Поэтому маленький остаток не доказывает отсутствие влияния. В точном МНК со смещением остатки всегда имеют

нулевое среднее - этот факт нельзя использовать как эмпирическое подтверждение $E[\varepsilon|X]=0$.

35 / ПРЕДЕЛЫ ИНТЕРПРЕТАЦИИ

Коэффициент и причинное воздействие

$E[Y|U=x]$ описывает наблюдаемую связь. $E[Y|do(X=x)]$ - средний ответ при вмешательстве, которое принудительно устанавливает признак. Равенство этих величин требует дополнительных условий и дизайна исследования.

В формуле пропущенного фактора коэффициент может быть ненулевым даже при $a_o=0$, если $\gamma Cov(U,Z)\neq 0$. Например, подготовленность до курса влияет и на время решения заданий, и на итоговый результат. Регрессия по времени смешает эти связи. Значимый коэффициент и высокий R^2 сами по себе не выделяют причинный эффект.

36 / ПРОВЕРИТЬ ПОНИМАНИЕ

Три коротких вывода своими руками

Попробуй ответить до раскрытия решения. Эти упражнения не меняют прогресс и доступны в любой момент.

Вопрос. В выборке все x одинаковы. Почему нельзя назвать единственный наклон?

Потому что $S_{xx}=0$ и столбец x кратен столбцу единиц. При $x=c$ любые a,b с $ac+b=\bar{y}$ дают один и тот же оптимальный прогноз. Определён прогноз на train, но не наклон.

Вопрос. Шум Лапласа имеет среднее 0 и одинаковую дисперсию. МНК стал смещённым?

Нет, если $E[\varepsilon|X]=0$ и X полного столбцового ранга. При независимых ошибках сохраняется BLUE. Изменилось другое: MLE соответствует MAE, а не MSE; точные нормальные t-интервалы без дополнительных аргументов применять нельзя.

Вопрос. Сделали два экземпляра каждой строки. Нужно ли вдвое усилить λ в MSE + λ‖w‖²?

Нет. MSE и штраф остаются теми же, значит оптимум не меняется. В формулах одновременно удваиваются X^TX, X^Ty и $n\lambda$. Однако копирование не создаёт независимых данных, поэтому нельзя считать, что неопределённость весов уменьшилась как от новых наблюдений.

37 / ИСТОЧНИКИ И МАРШРУТ ЧТЕНИЯ

Где продолжить разбор

Это самостоятельный синтез: доказательства изложены в единой системе обозначений, с собственным числовым примером и явными условиями применимости. В источниках могут отличаться знак остатка, буквы a и b, а также множители 1/n и 1/2 - сравнивай целиком функцию потерь.

РУССКОЯЗЫЧНЫЕ МАТЕРИАЛЫ

Андрей Хлевнюк - «Основы линейной регрессии»: ковариация и геометрия

Яндекс Учебник - линейные модели: МНК и регуляризация

Яндекс Учебник - вероятностный подход: шум и loss

Яндекс Учебник - байесовский подход: prior и posterior

О. А. Демидова, НИУ ВШЭ - Гаусс-Марков, оценки дисперсии и интервалы (PDF)