FIT&PREDICT

УЧЕБНИК МАШИННОГО ОБУЧЕНИЯ

Линейная регрессия.

Модель. Доказательства. Статистика.

От производных и ковариации до матричной проекции, случайного шума и доверительных интервалов. Пошаговые выводы, вычислительные примеры и границы применимости.

Редакция для совместной работы · 12 ноября 2026
37 разделов из теории сайта · формулы в векторном формате
Оглавление и ссылки на источники кликабельны.

МАРШРУТ ЧТЕНИЯ

Содержание

Три взгляда на одну модель: математический анализ, линейная алгебра, теория вероятностей и статистика.

1. Линейная регрессия

01 Одна прямая, три вопроса и немного паники

02 Кто все эти буквы?

03 Что именно в ней линейного?

04 Как измерить, насколько модель неправа?

05 Ищем лучшую прямую через производные

06 Откуда наклон знает про ковариацию?

07 Посчитаем руками (да, прям руками)

08 Normal equations, или МНК для любого числа признаков

09 Что, если веса не единственны?

10 МНК как тень: почему остаток перпендикулярен признакам

11 Что на самом деле делает кнопка «Один шаг»

12 Почему шагаем именно против градиента?

13 Какой learning rate не взорвёт обучение

14 Почему похожие признаки тормозят обучение

15 Batch, mini-batch и SGD: сколько данных на один шаг?

16 Что на самом деле предсказывает MSE?

17 Откуда берётся квадрат: нормальный шум и правдоподобие

18 А если шум не нормальный?

19 Насколько случайны найденные коэффициенты?

20 В каком смысле МНК — лучший?

21 От остатков к доверительным интервалам

22 Почему новый ответ предсказать сложнее, чем среднее

23 Что, если шум у всех разный?

24 Чего не исправит даже бесконечная выборка

25 Ridge: штрафуем веса, но не смещение

26 Bias и variance весов: бесплатных обедов не бывает

27 L1 против L2: почему Lasso умеет обнулять веса

28 Байесовский взгляд: MAP и веса после данных

29 Из чего состоит ошибка прогноза: bias² + variance + noise

30 Когда прямой мало: новые признаки

31 MSE, MAE и квантили: разные loss — разные вопросы

32 Минимум на train — ещё не победа

33 Что на самом деле оценивает validation

34 Модель обучилась. Что дальше?

35 Коэффициент — ещё не причина

36 О боже, домашка, нееееет :(

37 Что почитать дальше

ГЛАВА 1

Линейная регрессия.

Первая настоящая модель ML - и сразу полный набор математики: от производных a и b до матричной проекции, случайного шума и доверительных интервалов. Доказываем формулы, считаем руками и выясняем, где они перестают работать.

01 / ТРИ ВЗГЛЯДА НА РЕГРЕССИЮ

Одна прямая, три вопроса и немного паники

Добро пожаловать в главу про **ЛИНЕЙНУЮ РЕГРЕССИЮ** - первую настоящую модель машинного обучения в этом учебнике. Звучит скромно: «провести прямую через точки». Но за этой прямой прячется добрая половина математики, которая понадобится вам в ML дальше. (Да, я знаю, вы пришли учить нейросети. Нейросети подождут: каждый их слой начинается с той же самой формулы Xw+b.)

Возьмём простую задачу: по количеству часов подготовки предсказать балл за контрольную. Чтобы честно с ней разобраться, придётся по очереди задать три вопроса:

Математический анализ

«Какая прямая лучшая?» Производные найдут минимум ошибки, а ковариация объяснит наклон.

Линейная алгебра

«Почему именно она и всегда ли она одна?» МНК окажется проекцией, ранг ответит за единственность весов, а спектр - за устойчивость.

Теория вероятностей

«А если бы данные были другими?» Шум делает оценки случайными, а предположения о нём решают, насколько им можно верить.

Из багажа понадобятся производная, скалярное произведение, математическое ожидание и дисперсия. Всё остальное введём по ходу, прямо там, где оно впервые понадобится. Первые разделы вообще обходятся без матриц, а к статистике можно вернуться позже, когда наиграетесь с весами в интерактивном модуле.

> **Договоримся о правилах игры.** У каждого результата в этой главе есть условия, вычисления и вывод. Формула с обратной матрицей, у которой никто не проверил ранг, или доверительный интервал без модели шума - это не результат, а заклинание. Заклинания мы не учим.

02 / ОБОЗНАЧЕНИЯ

Кто все эти буквы?

Прежде чем бросаться в формулы, познакомимся с буквами. Их будет много, и, честно, это самая скучная часть главы. Зато потом не придётся гадать, что значит очередная закорючка с шапкой.

Обозначения в этом разделе

n, d, $p=d+1$	число объектов, исходных признаков и параметров с учётом смещения
x_i, y_i	признак и ответ i-го объекта в одномерном примере (те самые часы и баллы)
a, b	наклон и смещение в модели $\hat{y}=ax+b$. Осторожно: в некоторых источниках эти буквы переставлены, и это вечный источник путаницы
$\bar{x}$, $\bar{y}$	средние по выборке: $\Sigma x_i/n$ и $\Sigma y_i/n$
$X_0 \in \mathbb{R}^{n \times d}$	таблица исходных признаков: строка - объект, столбец - признак
$X=[1\ X_0] \in \mathbb{R}^{n \times p}$	матрица дизайна: те же признаки плюс первый столбец из единиц. Он нужен, чтобы спрятать смещение b внутрь β
$\beta=(b,w_1,\ldots,w_d)^T$	все параметры одним столбцом; $\hat{\beta}$ («бета с шапкой») - их оценка по данным
y, $\hat{y} \in \mathbb{R}^n$	столбец ответов и столбец прогнозов: $\hat{y}=X\beta$
$e=y-\hat{y}$, $r=\hat{y}-y=-e$	остатки. В литературе встречаются оба знака: в квадрате разницы нет, а вот в градиентах есть
ε	шум - ненаблюдаемая случайная добавка в истинном механизме. Не путать с остатком e: остаток мы видим, шум - никогда
E, Var, Cov	математическое ожидание, дисперсия и ковариация
U, Y	случайные признак и ответ. Букву X оставляем матрице, чтобы не сойти с ума
$\|v\|^2_2=\Sigma v_j^2$	квадрат евклидовой нормы, то есть квадрат длины вектора
A^T, I, tr(A)	транспонирование, единичная матрица и след - сумма диагональных элементов

Не пугайтесь записи $E[\varepsilon|X]=0$. Она означает всего лишь вот что: если зафиксировать *всю* матрицу признаков, шум в среднем равен нулю, то есть не тянет ответы систематически вверх или вниз. В чисто алгебраических разделах X и y - просто заданные числа, никакой случайности. Статистические предпосылки появятся позже, и я каждый раз буду говорить, какие именно.

03 / МОДЕЛЬ И ЗАДАЧА

Что именно в ней линейного?

Помните прямую y=kx+b из седьмого класса? Когда признаков несколько, каждому достаётся свой коэффициент, а всё вместе удобно записать через матрицу:

$$\hat{y}_i = b + \sum_{j=1}^{d} w_j x_{ij}, \qquad \hat{y} = X\beta$$

Одна строка X, умноженная на β, - это один прогноз. Все строки сразу - весь столбец прогнозов за одну операцию.

ВЕС w_j показывает, насколько изменится прогноз, если j-й признак вырастет на единицу, а все остальные останутся на месте. Единицы веса - единицы ответа, делённые на единицы признака. Поэтому, если измерить площадь квартиры в см² вместо м², вес уменьшится в 10 000 раз, а прогноз не изменится ни на копейку. Отсюда мораль: большой вес сам по себе ещё не означает «важный признак».

А теперь вопрос с подвохом: модель $b+w_1x+w_2x^2$ линейная? Внезапно, да! По исходному x это парабола, но по весам - обычная линейная комбинация. Именно это и важно: линейная регрессия линейна по **ПАРАМЕТРАМ**, а не по признакам. А вот exp(wx) уже нелинейна по w, и с ней этот фокус не пройдёт. Значит, всё, что мы дальше докажем про МНК, работает для любых заранее выбранных столбцов X, включая полиномиальные признаки.

04 / ЧТО МИНИМИЗИРУЕМ

Как измерить, насколько модель неправа?

Чтобы выбрать «лучшую» прямую, сначала нужно договориться, что значит «лучшая». Возьмём ошибку на каждом объекте, возведём в квадрат и усредним:

$$J(\beta) = \frac{1}{n}\|X\beta - y\|_2^2 = \frac{1}{n}\sum_i (\hat{y}_i - y_i)^2$$

МНК (OLS) - метод наименьших квадратов. SSE=nJ - сумма квадратов ошибок, то же самое без деления на n.

Зачем квадрат? Он не даёт плюсам и минусам сократиться, сильнее наказывает за большие промахи и, что немаловажно, гладко дифференцируется. Есть и более глубокая причина, связанная с шумом, но до неё дойдём в разделах про вероятность.

Важная бухгалтерия: все градиенты дальше посчитаны именно для MSE с множителем 1/n. Если взять SSE или J/2, точка минимума останется на месте, а вот градиент и допустимый learning rate изменятся. Масштаб регуляризации тоже придётся пересчитать. (Половина «у меня не сходится, как в статье» растёт именно отсюда.)

И ещё тонкость. МНК меряет ошибки **по вертикали**, в единицах ответа. Признаки и таргет в нём не равноправны: если обучить x по y и перевернуть полученную прямую, получится, как правило, другая прямая. А если ошибки измерения сидят в самих признаках, нужна уже отдельная модель.

05 / ВЫВОД A И B

Ищем лучшую прямую через производные

ВНИМАНИЕ, МАТЕМАТИКА! Начинается первый настоящий вывод. Пусть $n \geq 2$ и не все x_i равны (зачем это нужно, увидим в конце). Будем минимизировать $J(a,b)=\Sigma(ax_i+b-y_i)^2/n$ сразу по двум параметрам.

Идея простая: в точке минимума гладкой функции все частные производные равны нулю. Найдём их и приравняем к нулю.

От производных до формул

1

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_i (a x_i + b - y_i) = 0$$

Производная внутреннего выражения по b равна 1, а двойка вылезает из квадрата.

2

$$a\sum_i x_i + nb - \sum_i y_i = 0 \quad \Longrightarrow \quad \hat{b} = \overline{y} - \hat{a}\,\overline{x}$$

Делим на 2/n и раскрываем сумму. Бонус: прямая МНК со свободным членом всегда проходит через точку средних $(\bar{x},\bar{y})$.

3

$$\frac{\partial J}{\partial a} = \frac{2}{n}\sum_i x_i (a x_i + b - y_i) = 0$$

Теперь по a. Цепное правило добавляет множитель x_i.

4

$$\hat{a}\sum_i x_i (x_i - \overline{x}) = \sum_i x_i (y_i - \overline{y})$$

Подставляем найденное $\hat{b}=\bar{y}-\hat{a}\bar{x}$ в уравнение по a.

5

$$\sum_i x_i (x_i - \overline{x}) = \sum_i (x_i - \overline{x})^2,$$
$$\sum_i x_i (y_i - \overline{y}) = \sum_i (x_i - \overline{x})(y_i - \overline{y})$$

Фокус с центрированием: добавленные средние ничего не меняют, потому что сумма отклонений от среднего всегда равна нулю.

6

$$S_{xx} = \sum_i (x_i - \overline{x})^2, \qquad S_{xy} = \sum_i (x_i - \overline{x})(y_i - \overline{y})$$

Дадим этим двум числам имена: они ещё не раз нам встретятся.

7

$$\boxed{\widehat{a} = \frac{S_{xy}}{S_{xx}}, \qquad \hat{b} = \overline{y} - \widehat{a}\,\overline{x}}$$

$S_{xx}>0$ по условию, так что делить можно. Вот она, наша прямая!

А это точно минимум, а не максимум?

1

$$\nabla^2 J = \frac{2}{n}\begin{pmatrix} \sum_i x_i^2 & \sum_i x_i \\ \sum_i x_i & n \end{pmatrix}$$

Гессиан - матрица вторых производных по (a,b). Именно она говорит, куда «загибается» функция.

2

$$(u, v)\nabla^2 J(u, v)^\top = \frac{2}{n}\sum_i (u x_i + v)^2$$

Эта квадратичная форма - сумма квадратов, значит, неотрицательна. А при разных x_i она обнуляется только при u=v=0.

3

$$\det(\nabla^2 J) = \frac{4}{n^2}\left[n\sum_i x_i^2 - \left(\sum_i x_i\right)^2\right] = \frac{4S_{xx}}{n} > 0$$

Гессиан положительно определён, функция строго выпуклая - это «чаша» с единственным дном. Найденная точка - глобальный и единственный минимум.

А что, если все x одинаковые? Тогда $S_{xx}=0$, и данные просто не умеют различать a и b: любая пара с $ac+b=\bar{y}$ даёт одну и ту же минимальную ошибку. Представьте, что вы пытаетесь определить наклон прямой по точкам, выстроенным в один вертикальный столбик. Удачи. И отдельно: если заранее запретить смещение, получится $\hat{a}=\Sigma x_i y_i/\Sigma x_i^2$, а не формула через центрированную ковариацию.

06 / КОВАРИАЦИЯ И КОРРЕЛЯЦИЯ

Откуда наклон знает про ковариацию?

Формула $\hat{a}=S_{xy}/S_{xx}$ выглядит как набор закорючек. Но если поделить числитель и знаменатель на n, проступают знакомые лица:

$$\mathrm{Cov}_n(x,y) = \frac{S_{xy}}{n}, \quad \mathrm{Var}_n(x) = \frac{S_{xx}}{n},$$
$$\widehat{a} = \frac{\mathrm{Cov}_n(x,y)}{\mathrm{Var}_n(x)} = \rho_n \frac{s_y}{s_x}$$

$s_x^2=S_{xx}/n$, $s_y^2=\Sigma(y_i-\bar{y})^2/n$; корреляция ρ_n определена при $s_x,s_y>0$. Если в ковариации и дисперсии одновременно взять n−1, отношение не изменится, так что спор «n или n−1» здесь можно не начинать.

КОВАРИАЦИЯ положительна, когда x и y чаще отклоняются от своих средних в одну сторону: больше готовился - выше балл. Деление на дисперсию x переводит это «совместное шевеление» в понятные единицы: на сколько в среднем меняется y, когда x растёт на единицу. А если оба столбца стандартизовать, наклон и вовсе превратится в корреляцию.

Та же формула живёт не только на конкретной выборке, но и на уровне случайных величин. Вместо среднего по строкам там будет математическое ожидание по распределению:

Та же связь для случайных величин

1 $$R(a,b) = \mathbb{E}[(Y - aU - b)^2], \quad \mathbb{E}[U^2], \mathbb{E}[Y^2] < \infty, \quad \mathrm{Var}(U) > 0$$

Это риск по распределению, а не среднее по конкретным строкам. Раскрыв квадрат, получаем обычный многочлен от a и b.

2 $$\frac{\partial R}{\partial b} = 2(a\mathbb{E}[U] + b - \mathbb{E}[Y]) = 0,$$
$$b^* = \mathbb{E}[Y] - a^*\mathbb{E}[U]$$

Оптимальное смещение снова центрирует модель, как и на выборке.

3 $$R(a, b^*(a)) = \mathrm{Var}(Y) - 2a\,\mathrm{Cov}(U,Y) + a^2\,\mathrm{Var}(U)$$

Подставляем смещение и раскрываем квадрат центрированных величин.

4 $$\frac{\partial R}{\partial a} = -2\,\mathrm{Cov}(U,Y) + 2a\,\mathrm{Var}(U) = 0,$$
$$a^* = \frac{\mathrm{Cov}(U,Y)}{\mathrm{Var}(U)}$$

Вторая производная 2Var(U)>0, значит, минимум единственный.

5 $$Y = a_0 U + b_0 + \varepsilon \quad \Longrightarrow \quad a^* = a_0 + \frac{\mathrm{Cov}(U,\varepsilon)}{\mathrm{Var}(U)}$$

А вот и главное: коэффициент восстанавливает «истинный» a_0, только если признак линейно не связан с шумом. Условия $E[\varepsilon|U]=0$ для этого достаточно. Запомните эту формулу: она вернётся в разделе про пропущенные факторы.

И сразу предупреждение: нулевая ковариация **НЕ** означает независимость. Пусть U равномерно распределена на [−1,1], а $Y=U^2$. Тогда $\mathrm{Cov}(U,Y)=E[U^3]=0$, и лучшая прямая - горизонтальная константа $E[Y]=1/3$. Хотя Y полностью определяется U! Линейная модель смотрит на параболу и честно говорит: «Никакой связи не вижу». Так прямая может проморгать сильную нелинейную зависимость.

Продолжить чтение: Андрей Хлевнюк - «Основы линейной регрессии» ↗

07 / ПРИМЕР НА ЧЕТЫРЁХ ТОЧКАХ

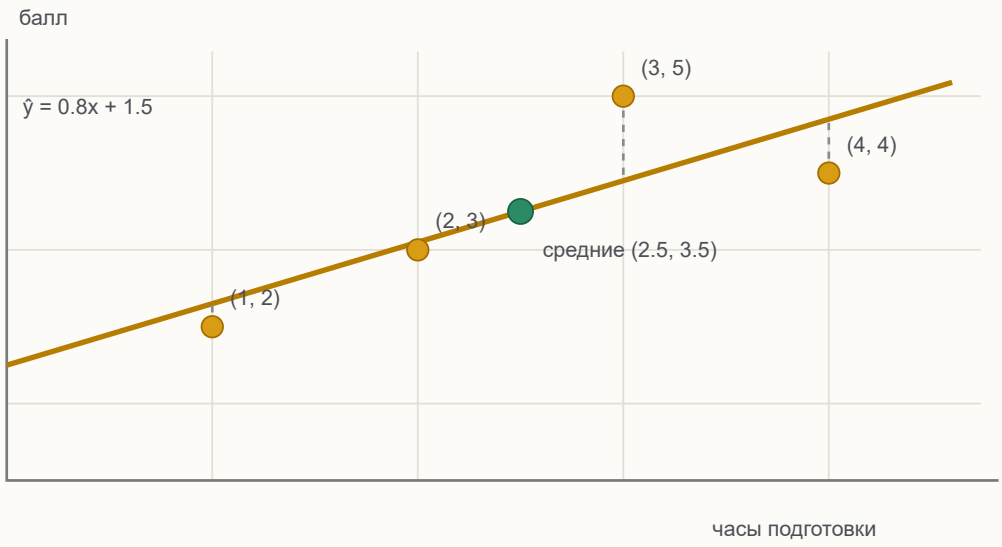
Посчитаем руками (да, прям руками)

Хватит букв, давайте числа. Возьмём четырёх школьников: часы подготовки x=(1,2,3,4) и условные баллы y=(2,3,5,4). Данные я, разумеется, придумал, так что выводы об успеваемости по ним делать не надо. (Третий школьник просто очень талантливый.)

Полный расчёт одномерного МНК

x	y	x−x̄	y−ȳ	(x−x̄)(y−ȳ)	ŷ	e=y−ŷ
1	2	−1.5	−1.5	2.25	2.3	−0.3
2	3	−0.5	−0.5	0.25	3.1	−0.1
3	5	0.5	1.5	0.75	3.9	1.1
4	4	1.5	0.5	0.75	4.7	−0.7

$$\overline{x}=2.5,\quad \overline{y}=3.5,\quad S_{xx}=5,\quad S_{xy}=4,$$
$$\widehat{a}=0.8,\quad \hat{b}=1.5,\quad \mathrm{SSE}=1.8,\quad \mathrm{MSE}=0.45$$



Линия проходит через средние. Пунктир - вертикальные ошибки на наблюдениях; МНК минимизирует сумму их квадратов, а не перпендикулярные расстояния до прямой.

Проверим, что это действительно оптимум: $\Sigma e_i = 0$ и $\Sigma x_i e_i = -0.3 - 0.2 + 3.3 - 2.8 = 0$. Это ровно две частные производные из прошлого вывода, и обе равны нулю. Сходится!

Но не обольщайтесь: эти равенства выполнены, *потому что* мы так обучили модель. После МНК остатки всегда ортогональны признакам, даже если мир устроен совсем не линейно. Поэтому они ничего не доказывают про независимость ненаблюдаемого шума от признаков.

08 / МАТРИЧНЫЙ ДИФФЕРЕНЦИАЛ

Normal equations, или МНК для любого числа признаков

Две производные по a и b - это мило. Но в задаче про квартиры было пять признаков, а в реальной жизни бывают тысячи. Расписывать каждую производную вручную? Нет, спасибо. Вспоминаем линейную алгебру.

Теперь у нас p параметров, $X \in \mathbb{R}^{n \times p}$ и $\beta \in \mathbb{R}^{p}$. X и y при дифференцировании фиксированы. Малое приращение $d\beta$ - столбец той же размерности, что β, а для скалярной функции $dJ = (\nabla J)^{\top} d\beta$. То есть градиент - это то, что стоит перед $d\beta$. Его и будем вылавливать.

Дифференцируем матричную запись

1

$$r = X\beta - y, \qquad J = \frac{r^{\top} r}{n}, \qquad dr = X\, d\beta$$

Умножение на матрицу линейно, поэтому дифференциал остатка получается сразу, без поэлементного разворачивания.

2

$$dJ = \frac{(dr)^\top r + r^\top dr}{n} = \frac{2}{n} r^\top dr$$

Оба слагаемых - одно и то же число: скаляр равен своему транспонированию.

3

$$dJ = \frac{2}{n} r^\top X\, d\beta = \left[\frac{2}{n} X^\top r\right]^\top d\beta$$

Переставляем множители только через транспонирование. Менять порядок матриц как попало нельзя, это вам не числа.

4

$$\nabla J(\beta) = \frac{2}{n} X^\top (X\beta - y), \qquad \nabla^2 J = \frac{2}{n} X^\top X$$

Считываем коэффициент перед dβ - вот и градиент. Дифференцируем ещё раз - получаем гессиан.

5

$$\nabla J = 0 \quad \Longleftrightarrow \quad X^\top X \widehat{\beta} = X^\top y$$

Это и есть **НОРМАЛЬНЫЕ УРАВНЕНИЯ**. «Нормальные» тут означает «перпендикулярные», а не «гауссовские» и не «обычные».

6

$$\operatorname{rank}(X) = p \quad \Longrightarrow \quad \boxed{\widehat{\beta} = (X^\top X)^{-1} X^\top y}$$

Обратная матрица существует, когда столбцы X линейно независимы. В частности, нужно n≥p: объектов не меньше, чем параметров.

7

$$h^\top \nabla^2 J h = \frac{2}{n} \|Xh\|^2 > 0 \qquad (h \neq 0)$$

При полном столбцовом ранге функция строго выпуклая, а минимум единственный и глобальный.

Тот же градиент можно получить и в лоб, раскрыв $J=(\beta^\top X^\top X\beta - 2y^\top X\beta + y^\top y)/n$ и вспомнив, что производная $\beta^\top A\beta$ равна $(A+A^\top)\beta$. Здесь $A=X^\top X$ симметрична, поэтому выходит $2A\beta$. Но без симметрии формула «2Aβ» неверна, и на этом регулярно сыпятся на экзаменах.

$$X^\top X \in \mathbb{R}^{p\times p}, \qquad X^\top y \in \mathbb{R}^{p\times 1}, \qquad \widehat{\beta} \in \mathbb{R}^{p\times 1}$$

Свободный член уже сидит первым элементом β (помните столбец единиц?). Прибавлять после этой формулы ещё один отдельно обученный b не нужно.

Продолжить чтение: Яндекс Учебник - линейные модели ↗

Что, если веса не единственны?

Представьте, что в таблице квартир кто-то дважды записал площадь: в одном столбце и в другом. Модели всё равно, какой из двух весов увеличить: прибавьте t к одному и вычтите t из другого - прогнозы не изменятся ни на рубль. Значит, «лучших» весов бесконечно много.

В общем случае такая невидимая добавка - это направление h из **ЯДРА** матрицы: Xh=0. Данные его просто не видят. Чтобы аккуратно описать все решения, понадобится SVD - сингулярное разложение.

Все решения через компактное SVD

1 $$X = U_r \Sigma_r V_r^\top, \quad \operatorname{rank}(X) = r, \quad \Sigma_r = \operatorname{diag}(s_1, \dots, s_r),\ s_j > 0$$

Столбцы U_r и V_r ортонормированы. Компактное разложение оставляет только ненулевые сингулярные значения.

2 $$\|y - X\beta\|^2 = \|U_r^\top y - \Sigma_r V_r^\top \beta\|^2 + \|(I - U_r U_r^\top) y\|^2$$

Раскладываем y на часть внутри пространства столбцов X и часть, перпендикулярную ему. По теореме Пифагора квадраты норм складываются, а второе слагаемое от β вообще не зависит: его не победить никакими весами.

3 $$\Sigma_r V_r^\top \beta = U_r^\top y \quad \Longrightarrow \quad V_r^\top \beta = \Sigma_r^{-1} U_r^\top y$$

Первое слагаемое можно обнулить. Все диагональные значения Σ_r положительны, так что обращать можно.

4 $$X^+ = V_r \Sigma_r^{-1} U_r^\top, \qquad \widehat{\beta}_0 = X^+ y$$

Псевдообратная матрица определена даже при r<p, когда обычной обратной не существует.

5 $$\widehat{\beta} = X^+ y + h, \qquad h \in \ker(X)$$

Все МНК-решения отличаются только той самой невидимой для данных компонентой.

6 $$\hat{y} = X X^+ y = U_r U_r^\top y$$

А вот прогнозы на train единственны, даже когда коэффициенты - нет.

7 $$\|\widehat{\beta}_0 + h\|^2 = \|\widehat{\beta}_0\|^2 + \|h\|^2$$

β_0 лежит в пространстве строк X, перпендикулярном ядру. Поэтому это решение с наименьшей нормой - самое «скромное» из всех.

Если признаков больше, чем объектов (n<p), полного столбцового ранга не бывает в принципе. А при полном строковом ранге r=n модель может провести поверхность ровно через все точки и получить нулевую ошибку на train. Звучит как победа, но нет: на новом объекте $x_0^T h$ может оказаться каким угодно. Классическая дорогая зубрёжка.

И практический момент: в реальном коде $(X^TX)^{-1}$ явно обычно не строят. При полном ранге тонкое QR-разложение X=QR превращает задачу в треугольную систему $R\hat{\beta}=Q^Ty$, а SVD умеет находить почти зависимые направления. Причина простая: для спектрального числа обусловленности $\kappa_2(X^TX)=\kappa_2(X)^2$, то есть нормальные уравнения возводят численную неустойчивость в квадрат.

10 / ПРОЕКЦИЯ И R^2

МНК как тень: почему остаток перпендикулярен признакам

Помните, в уроке про линейную алгебру я обещал, что скалярное произведение и перпендикулярность нам ещё пригодятся? Время пришло. Оказывается, МНК можно доказать вообще без производных - одной теоремой Пифагора.

Идея такая: все возможные прогнозы Xβ образуют подпространство, натянутое на столбцы X. Настоящий y в него обычно не попадает. Ближайшая к нему точка подпространства - его **ПРОЕКЦИЯ**, «тень», которую y отбрасывает, если светить строго перпендикулярно.

Геометрическое доказательство МНК

1 $$P = XX^{+} = U_r U_r^{\top}, \qquad P^{\top} = P, \qquad P^2 = P$$

P - ортогональный проектор на пространство столбцов X. Применить его дважды - то же, что один раз: тень от тени - та же тень.

2 $$\hat{y} = Py, \qquad e = (I - P)y, \qquad X^{\top} e = 0$$

Остаток перпендикулярен всему пространству допустимых прогнозов.

3 $$y - X\beta = e + (\hat{y} - X\beta)$$

Разбиваем расстояние до любого кандидата на два перпендикулярных куска.

4 $$\|y - X\beta\|^2 = \|e\|^2 + \|\hat{y} - X\beta\|^2 \geq \|e\|^2$$

Теорема Пифагора: квадрат гипотенузы не меньше квадрата катета. Глобальный минимум доказан, и ни одной производной.

Если в X есть столбец единиц, то $1^Te=0$: средний остаток равен нулю, среднее прогнозов равно $\bar{y}$, а e перпендикулярен $\hat{y}-\bar{y}1$. При $S_{YY}=\Sigma(y_i-\bar{y})^2>0$ отсюда получается знаменитое разложение:

$$S_{yy} = \|y - \bar{y}\mathbf{1}\|^2 = \|\hat{y} - \bar{y}\mathbf{1}\|^2 + \mathrm{SSE},$$
$$R^2 = 1 - \frac{\mathrm{SSE}}{S_{yy}} \in [0, 1]$$

R^2 - доля разброса y, которую объяснила модель. Для одного признака $\hat{a}=S_{xy}/S_{xx}$, поэтому $\|\hat{y}-\bar{y}\mathbf{1}\|^2=\hat{a}^2S_{xx}=S_{xy}^2/S_{xx}$ и $R^2=S_{xy}^2/(S_{xx}S_{yy})=\rho_n^2$. В примере с четырьмя школьниками $R^2=16/25=0.64$. Для нескольких признаков это уже не квадрат корреляции с каким-то одним из них.

Мелкий шрифт. Разложение и границы [0,1] верны для МНК **на train и со смещением**. На validation или test R^2 спокойно бывает отрицательным: модель оказалась хуже, чем константа-среднее. Без смещения или со штрафом ортогональное разложение не гарантировано. А при постоянном y знаменатель равен нулю, и R^2 не определён вовсе.

11 / ПОКООРДИНАТНЫЙ ГРАДИЕНТ

Что на самом деле делает кнопка «Один шаг»

Нормальные уравнения - это красиво, но когда признаков сотни тысяч, обращать матрицу p×p - удовольствие сомнительное. (Excel уже не просто подозревает неладное, он ушёл в отпуск.) Поэтому на практике веса часто ищут итеративно, **ГРАДИЕНТНЫМ СПУСКОМ**: начинаем с каких-нибудь весов и много раз чуть-чуть сдвигаем их туда, где ошибка меньше.

Для этого нужна производная ошибки по каждому весу. Посчитаем её честно, по одному параметру за раз:

Цепное правило по каждому весу

1
$$r_i = b + \sum_j w_j x_{ij} - y_i, \qquad J = \frac{1}{n}\sum_i r_i^2$$

Фиксируем знак ошибки: прогноз минус ответ. С другим знаком всё тоже работает, но минусы поедут.

2
$$\frac{\partial r_i}{\partial w_j} = x_{ij}, \qquad \frac{\partial r_i}{\partial b} = 1$$

Меняем только один параметр, всё остальное считаем константами.

3
$$\frac{\partial (r_i^2)}{\partial w_j} = 2 r_i x_{ij}$$

Производная внешнего квадрата умножается на производную того, что внутри.

4

$$\frac{\partial J}{\partial w_j} = \frac{2}{n}\sum_i r_i x_{ij}$$

Усредняем вклад всех объектов.

5

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_i r_i$$

У смещения вместо признака стоит столбец единиц, поэтому остаётся просто сумма остатков.

6

$$w_j \leftarrow w_j - \eta\frac{\partial J}{\partial w_j}, \qquad b \leftarrow b - \eta\frac{\partial J}{\partial b}$$

Важно: все производные одного шага считаются по *старым* параметрам и только потом применяются разом. Обновлять веса по одному и тут же использовать новые - это уже другой алгоритм.

Проверим на наших четырёх точках. При a=b=0 получаем ∂J/∂a=−19.5 и ∂J/∂b=−7. С η=0.05 первый шаг даст a=0.975, b=0.35. До оптимума (0.8,1.5) ещё далеко, а a даже проскочил мимо, но MSE уже упала с 13.5 примерно до 1.0.

12 / ПОЧЕМУ ПРОТИВ ГРАДИЕНТА

Почему шагаем именно против градиента?

Почему минус градиент, а не просто «куда-нибудь вниз»? Представьте, что вы стоите на склоне в густом тумане и видите только землю под ногами. Быстрее всего спуститься, если шагнуть туда, где склон круче всего уходит вниз. Градиент указывает направление самого крутого подъёма, значит, нам в противоположную сторону. Докажем это аккуратно:

Тейлор и Коши-Буняковский

1

$$J(\beta + hv) = J(\beta) + h\langle \nabla J(\beta), v\rangle + o(h), \qquad \|v\|_2 = 1$$

Первое приближение Тейлора: при маленьком шаге h изменение функции почти целиком определяется производной по направлению v.

2

$$\langle \nabla J, v\rangle \geq -\|\nabla J\|_2\|v\|_2 = -\|\nabla J\|_2$$

Неравенство Коши-Буняковского ограничивает, насколько быстро вообще можно убывать.

3

$$v^* = -\frac{\nabla J}{\|\nabla J\|_2} \qquad (\nabla J \neq 0)$$

Ровно в направлении антиградиента эта нижняя граница достигается. А если градиент нулевой, все производные первого порядка равны нулю: мы в стационарной точке.

Но обратите внимание: это утверждение про *бесконечно малый* шаг. С конечным η нужно ещё учитывать кривизну: даже в правильном направлении слишком длинный шаг перепрыгнет через яму и окажется выше, чем был. Сколько именно «слишком» - в следующем разделе.

13 / ДОКАЗАТЕЛЬСТВО СХОДИМОСТИ

Какой learning rate не взорвёт обучение

Все, кто хоть раз обучал модель, видели, как loss улетает в бесконечность после слишком смелого learning rate. Давайте выясним, где проходит граница. Обозначим $H=2X^TX/n$. При полном столбцовом ранге его собственные значения $0<\mu_1\le\ldots\le\mu_p$. Пусть $q_t=\beta_t-\hat{\beta}$ - насколько текущие веса отстоят от оптимальных.

Что происходит с ошибкой на каждом шаге

1 $$\nabla J(\beta_t) = H(\beta_t - \widehat{\beta}), \qquad q_{t+1} = (I - \eta H) q_t$$

Вычитаем нормальные уравнения из текущего градиента, и ошибка весов просто умножается на матрицу.

2 $$H = V\,\mathrm{diag}(\mu_j)V^\top, \qquad c_t = V^\top q_t$$

Переходим в базис собственных векторов H, где матрица становится диагональной.

3 $$c_{t+1,j} = (1 - \eta\mu_j)\,c_{t,j}$$

Каждое направление теперь живёт своей жизнью и не мешает остальным.

4 $$|1 - \eta\mu_j| < 1 \;\; (\forall j) \quad\Longleftrightarrow\quad 0 < \eta < \frac{2}{\mu_p}$$

Все компоненты затухают тогда и только тогда, когда шаг меньше $2/\mu_p$. Отсюда $\beta_t\to\hat{\beta}$.

5 $$\|q_t\|_2 \le \rho^t \|q_0\|_2, \qquad \rho = \max_j |1 - \eta\mu_j| < 1$$

Получаем даже скорость: ошибка убывает как геометрическая прогрессия.

Ровно на границе $\eta=2/\mu_p$ старшая компонента просто меняет знак и не уменьшается: веса качаются туда-сюда. Выше границы она растёт (если присутствовала в начальной ошибке) - привет, NaN в логах. А при неполном ранге нулевые направления не меняются вовсе: прогнозы сходятся, но компонента весов в ядре навсегда остаётся такой, какой была при инициализации.

$$J(\beta - \eta g) = J(\beta) - \eta \|g\|^2 + \frac{\eta^2}{2} g^\top H g, \qquad g = \nabla J(\beta)$$

Для квадратичной функции формула Тейлора точна, без всяких «приблизительно». При $0<\eta<2/\mu_p$ и $g\neq 0$ из $g^\top H g \le \mu_p \|g\|^2$ следует, что loss строго убывает на каждом шаге.

Когда остановиться? На практике - по заданной точности, а не по точному равенству весов. Маленький шаг может означать просто маленький η. Градиент, округлённый до 0.000, может быть ненулевым. А при полном ранге $J(\beta)-J(\beta') \le \|\nabla J(\beta)\|^2/(2\mu_1)$, поэтому один и тот же «маленький» градиент даёт совсем разные гарантии при разной обусловленности.

14 / МАСШТАБ И ОБУСЛОВЛЕННОСТЬ

Почему похожие признаки тормозят обучение

Представьте чашу ошибки. Если она круглая, антиградиент смотрит прямо в дно, и спуск идёт бодро. А если она вытянута в длинный узкий овраг, антиградиент смотрит в основном поперёк оврага: веса скачут от стенки к стенке и очень медленно ползут вдоль дна.

Насколько чаша вытянута, измеряет **ЧИСЛО ОБУСЛОВЛЕННОСТИ** $\kappa=\mu_p/\mu_1$. Даже при лучшем постоянном шаге $\eta^*=2/(\mu_1+\mu_p)$ худший множитель сжатия равен $(\kappa-1)/(\kappa+1)$. При огромном κ он почти равен 1: тысячи шагов почти не двигают веса вдоль слабого направления.

Стандартизация приводит столбцы к сравнимым масштабам, но почти линейную зависимость она не лечит. Если общая и жилая площадь квартиры почти дублируют друг друга, веса могут уползать в противоположные стороны, пока прогноз стоит на месте. Отсюда важная разница между «прогноз уже стабилен» и «коэффициенты точно определены».

И правило гигиены: средние и масштабы считаем **только на train**. Для $z_j=(x_j-m_j)/s_j$ и модели $b_z+\Sigma w_z_j z_j$ вернуться к исходным единицам можно так: $w_x_j=w_z_j/s_j$ и $b_x=b_z-\Sigma w_z_j m_j/s_j$. А постоянный признак с $s_j=0$ делить на стандартное отклонение нельзя: при наличии смещения он всё равно ничего не добавляет.

15 / BATCH И SGD

Batch, mini-batch и SGD: сколько данных на один шаг?

Считать градиент по всем n объектам на каждом шаге - честно, но дорого. Когда строк миллион, хочется схитрить и оценить градиент по случайной кучке объектов:

$$g_t = \frac{1}{m}\sum_{i\in B_t}\nabla \ell_i(\beta_t), \qquad \beta_{t+1} = \beta_t - \eta_t g_t$$

FULL BATCH использует все n строк, **SGD** - одну, **MINI-BATCH** - m строк. Если индексы выбираются равномерно и независимо от прошлых шагов, условное ожидание g_t равно полному градиенту: в среднем мы идём куда надо, просто с шумом. Только не путайте единицы: *эпоха* - это просмотр n объектов, *шаг* - одно обновление. Поэтому «100 шагов» у разных алгоритмов - совсем разный объём работы.

С постоянным η шум SGD обычно не даёт весам буквально остановиться: они так и дрожат вокруг минимума. Чтобы сойтись точно, нужны дополнительные условия - типично $\Sigma\eta_t=\infty$ и $\Sigma\eta_t^2<\infty$, плюс контроль дисперсии стохастических градиентов и устойчивость итераций. В интерактивном модуле используется полный градиент, поэтому движение детерминировано: повторите обучение с теми же данными и настройками - получите то же самое.

16 / УСЛОВНОЕ СРЕДНЕЕ

Что на самом деле предсказывает MSE?

До сих пор мы просто минимизировали ошибку на конкретных числах. Пора задать неудобный вопрос: а что мы вообще пытаемся приблизить? Ответ - **УСЛОВНОЕ СРЕДНЕЕ**.

Пусть $Y=m(U)+\varepsilon$, где $m(u)=E[Y|U=u]$ - средний ответ при данном значении признака, а $E[Y^2]<\infty$. Тогда $E[\varepsilon|U]=0$ просто по определению. Признаки тоже могут быть случайными; при обучении мы видим одну их реализацию.

Почему MSE ищет именно условное среднее

1 $$Y - g(U) = \varepsilon + m(U) - g(U)$$

Добавляем и вычитаем условное среднее - старый добрый трюк. Здесь g - любая функция прогноза с конечным риском.

2 $$\mathbb{E}[(Y-g(U))^2 \mid U] = \mathbb{E}[\varepsilon^2 \mid U] + (m(U)-g(U))^2 + 2(m(U)-g(U))\mathbb{E}[\varepsilon \mid U]$$

При фиксированном U разность $m(U)-g(U)$ - просто константа.

3 $$\mathbb{E}[(Y-g(U))^2 \mid U] = \mathbf{Var}(Y \mid U) + (m(U)-g(U))^2$$

Перекрёстное слагаемое обнуляется, потому что шум в среднем равен нулю.

4

$$\arg\min_{g} \mathbb{E}[(Y - g(U))^2] = m(U) \quad \text{почти наверное}$$

Осталось минимизировать неотрицательный квадрат, и ноль достигается при g=m. Заметьте: нормальность шума нигде не понадобилась!

Если ограничиться прямыми, мы найдём лучшую *линейную* аппроксимацию m(U). С самим m(U) она совпадёт, только если условное среднее действительно линейно. Идеально сошедшийся градиентный спуск не исправит неправильно выбранный класс функций: он найдёт лучшую прямую, а не лучшую кривую.

Три предположения, которые часто сваливают в одну кучу. E[ε|X]=0 достаточно, чтобы МНК был несмещённым при полном ранге. Постоянная дисперсия и некоррелированность нужны для классической формулы дисперсии. Нормальность добавляет точные распределения оценок и статистик на конечной выборке. Это три разные ступеньки, и каждая - отдельная гипотеза о мире.

17 / НОРМАЛЬНЫЙ ШУМ → MSE

Откуда берётся квадрат: нормальный шум и правдоподобие

Помните, я обещал объяснить, почему в MSE именно квадрат? Вот объяснение. Предположим, что условно на X шум ε~N(0,σ²I), σ²>0: ошибки независимы, нормальны и имеют одну и ту же дисперсию. Обратите внимание: нормальными должны быть именно ошибки, а сами признаки и ответы - не обязаны.

Метод **МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ** предлагает выбрать такие параметры, при которых наблюдаемые данные выглядят наиболее «ожидаемыми».

От плотности к оптимизации

1

$$p(y \mid X, \beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|y - X\beta\|^2}{2\sigma^2}\right)$$

Совместная плотность - произведение n нормальных плотностей. Это именно плотность: вероятность получить ровно такие y для непрерывных величин равна нулю.

2

$$-\log p = \frac{n}{2}\log(2\pi\sigma^2) + \frac{\mathrm{SSE}(\beta)}{2\sigma^2}$$

Логарифм превращает произведение в сумму - и внезапно появляется SSE.

3

$$\arg\min_{\beta}(-\log p) = \arg\min_{\beta}\mathrm{SSE}(\beta) = \widehat{\beta}_{\mathrm{OLS}}$$

При фиксированной дисперсии константа и положительный множитель не влияют на то, где минимум. Максимум правдоподобия - это минимум суммы квадратов. Бинго!

4

$$\frac{\partial(-\log p)}{\partial v} = \frac{n}{2v} - \frac{\mathrm{SSE}}{2v^2} = 0, \qquad v = \sigma^2$$

Если дисперсия неизвестна, её тоже можно оценить: дифференцируем по v=σ².

5

$$\widehat{\sigma}^2_{\mathrm{MLE}} = \frac{\mathrm{SSE}(\widehat{\beta})}{n}$$

При SSE>0 это оптимум по v>0. Но несмещённая оценка другая, SSE/(n−p); почему - разберём через пару разделов.

Есть и вырожденный случай: если SSE=0 (например, при интерполяции), правдоподобие неограниченно растёт при σ²→0, и конечной MLE с положительной дисперсией нет. А ЦПТ иногда оправдывает приближённую нормальность, когда шум складывается из множества мелких влияний, но не доказывает её для любого шума. (Источник фразы «шум всегда нормальный» - поверь мне, брат. Не верьте.)

Продолжить чтение: Яндекс Учебник - вероятностный подход в ML ↗

18 / ДРУГИЕ РАСПРЕДЕЛЕНИЯ ШУМА

А если шум не нормальный?

Нормальный шум дал нам MSE. Логичный вопрос: а если шум другой? Для независимых ошибок с известной общей плотностью q и фиксированными параметрами масштаба отрицательное лог-правдоподобие равно $\Sigma_i - \log q(e_i)$, где $e_i = y_i - x_i^T\beta$. Получается, каждая гипотеза о шуме автоматически рождает свою функцию потерь:

Связь распределения шума с обучением

Нормальный	
Плотность $q(e) \propto \exp\left(-\frac{e^2}{2\sigma^2}\right)$	Отрицательный log-loss, без константы $\frac{e^2}{2\sigma^2}$
МНК; штраф растёт квадратично, большие промахи наказываются очень больно.	

Лаплас, масштаб c>0

Плотность

$$q(e) = \frac{\exp(-|e|/c)}{2c}$$

Отрицательный log-loss, без константы

$$\frac{|e|}{c}$$

MAE; в точечной задаче оптимальна условная медиана.

Стьюдент, v>0, масштаб s>0

Плотность

$$q(e) \propto \left(1 + \frac{e^2}{\nu s^2}\right)^{-(\nu+1)/2}$$

Отрицательный log-loss, без константы

$$\frac{\nu+1}{2} \log\left(1 + \frac{e^2}{\nu s^2}\right)$$

Хвосты штрафуются мягче, но оптимизация в общем случае невыпуклая.

Коши, масштаб c>0

Плотность

$$q(e) = \frac{1}{\pi c[1 + (e/c)^2]}$$

Отрицательный log-loss, без константы

$$\log\left(1 + (e/c)^2\right)$$

Частный случай v=1; нет ни среднего, ни дисперсии, так что привычные рассуждения про MSE-риск не работают.

Равномерный на [−c,c]

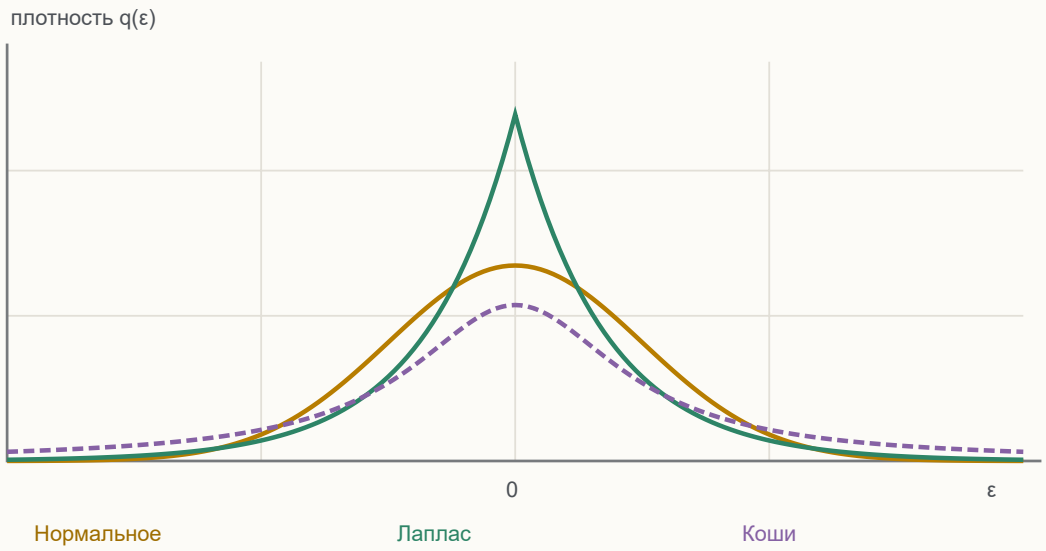
Плотность

$$q(e) = \begin{cases} \frac{1}{2c}, & |e| \le c, \\ 0, & |e| > c \end{cases}$$

Отрицательный log-loss, без константы

$$\begin{cases} \text{const}, & |e| \le c, \\ +\infty, & |e| > c \end{cases}$$

При известном c все допустимые веса одинаково правдоподобны: правдоподобие ничего не выбирает.



Нормальное N(0,1) и Лаплас с масштабом 1/√2 имеют дисперсию 1. У Коши с масштабом 1 дисперсии и математического ожидания нет; его хвост убывает как 1/ε². Кривые вычислены по плотностям, а не нарисованы произвольно.

У Лапласа конечная дисперсия $2c^2$. Поэтому при нулевом условном среднем МНК всё ещё несмещён, хотя уже не совпадает с MLE. У Стьюдента среднее существует при $\nu>1$, дисперсия - при $\nu>2$. Симметричная плотность сама по себе ещё не гарантирует, что у неё есть математическое ожидание. (Коши передаёт привет.)

Если у равномерного шума неизвестен масштаб, его MLE при фиксированных весах равна $\max_i|e_i|$. Подставив её, получим задачу минимизации *максимального* модуля остатка, а не суммы квадратов. И при точной интерполяции масштаб снова вырождается в ноль.

Асимметричный шум с конечным средним можно центрировать, но у такого шума центр, медиана и среднее - вообще разные числа. Например, $\varepsilon=Z-1$ для $Z\sim\mathrm{Exp}(1)$ имеет среднее 0, но медиану $\log 2-1$. Тогда MSE и MAE решают разные задачи даже на бесконечных данных.

> **Частая ошибка:** посмотреть на гистограмму таргета и сделать вывод о шуме. Распределение шума - это отклонения ответов *при фиксированных признаках*, а не распределение самих ответов. И даже нормальность обученных остатков ещё не означает, что истинные ошибки независимы.

19 / НЕСМЕЩЁННОСТЬ И ДИСПЕРСИЯ

Насколько случайны найденные коэффициенты?

Мысленный эксперимент. Соберите другую группу школьников - получите другие веса. Ещё одну - снова другие. Получается, $\hat{\beta}$ - это **СЛУЧАЙНАЯ ВЕЛИЧИНА**, и у неё можно спросить среднее и разброс.

Предположим $y=X\beta_0+\varepsilon$, $\operatorname{rank}(X)=p$, $\mathbb{E}[\varepsilon|X]=0$ и конечную $\Omega=\operatorname{Cov}(\varepsilon|X)$. Положим $A=(X^TX)^{-1}X^T$, тогда $AX=I$.

Два свойства линейной оценки

1 $$\widehat{\beta} = Ay = AX\beta_0 + A\varepsilon = \beta_0 + A\varepsilon$$

Вся случайность весов - это линейное преобразование шума.

2 $$\mathbb{E}[\widehat{\beta} \mid X] = \beta_0 + A\mathbb{E}[\varepsilon \mid X] = \beta_0$$

Условная несмещённость: в среднем по повторным выборкам попадаем ровно в β_0. Если безусловное ожидание существует, то и $\mathbb{E}[\hat{\beta}]=\beta_0$.

3 $$\operatorname{Cov}(\widehat{\beta} \mid X) = A\Omega A^{\top}$$

При фиксированном X матрица A постоянна, и ковариация преобразуется слева и справа.

4 $$\Omega = \sigma^2 I \quad\Longrightarrow\quad \operatorname{Cov}(\widehat{\beta} \mid X) = \sigma^2 (X^{\top}X)^{-1}$$

Используем $AA^T=(X^TX)^{-1}$. И снова нормальность не понадобилась.

$$\operatorname{Var}(\widehat{a} \mid x) = \frac{\sigma^2}{S_{xx}},$$
$$\operatorname{Var}(\hat{b} \mid x) = \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}} \right),$$
$$\operatorname{Cov}(\widehat{a}, \hat{b} \mid x) = -\frac{\sigma^2 \overline{x}}{S_{xx}}$$

Одномерный случай: $\hat{a}-a_0=\Sigma(x_i-\bar{x})\varepsilon_i/S_{xx}$, $\hat{b}-b_0=\bar{\varepsilon}-\bar{x}(\hat{a}-a_0)$. Из $\Sigma(x_i-\bar{x})=0$ следует $\operatorname{Cov}(\bar{\varepsilon},\hat{a})=0$, а подстановка даёт все три формулы.

Посмотрите на σ^2/S_{xx}: чем шире разброс x, тем точнее оценивается наклон при том же шуме. Интуитивно понятно: по точкам, сбившимся в кучку, наклон определить сложно, а по разбросанным - легко. Отсюда же неустойчивость при маленьком S_{xx}.

И про слово «несмещённая»: оно значит «правильная *в среднем* по повторным выборкам», а не «точная в каждом конкретном наборе». Несмещённый стрелок может каждый раз промахиваться на метр - просто то влево, то вправо.

В каком смысле МНК - лучший?

Красивое утверждение с громким названием. При полном ранге, E[ε|X]=0 и Cov(ε|X)=σ²I МНК имеет наименьшую условную дисперсию среди всех оценок, которые *линейны по y* и несмещены при любом β₀. Такие оценки называют **BLUE** - Best Linear Unbiased Estimator. И нет, нормальность снова не нужна.

Доказательство через произвольного конкурента

1

$$\widetilde{\beta} = Cy, \qquad \mathbb{E}[\widetilde{\beta} \mid X] = CX\beta_0$$

Берём произвольного конкурента. C может зависеть от X, но не от ответов y.

2

$$\mathbb{E}[\widetilde{\beta} \mid X] = \beta_0 \ \ (\forall \beta_0) \quad \Longleftrightarrow \quad CX = I$$

Требование несмещённости при любом β₀ превращается в матричное условие.

3

$$C = A + D, \qquad A = (X^\top X)^{-1} X^\top \quad \Longrightarrow \quad DX = 0$$

Отделяем МНК-часть от «авторской добавки» конкурента.

4

$$AD^\top = (X^\top X)^{-1} X^\top D^\top = (X^\top X)^{-1} (DX)^\top = 0$$

Перекрёстные члены в ковариации исчезают.

5

$$\mathrm{Cov}(\widetilde{\beta} \mid X) - \mathrm{Cov}(\widehat{\beta} \mid X) = \sigma^2 DD^\top$$

Раскрываем σ²(A+D)(A+D)ᵀ: от разницы остаётся только σ²DDᵀ.

6

$$v^\top [\mathrm{Cov}(\widetilde{\beta} \mid X) - \mathrm{Cov}(\widehat{\beta} \mid X)] v = \sigma^2 \| D^\top v \|^2 \geq 0$$

Ни одну линейную комбинацию коэффициентов конкурент не оценит с меньшей дисперсией. МНК победил.

Но читайте условия теоремы, а не только название. Она не утверждает, что МНК лучше всех возможных процедур, и не запрещает ridge иметь меньшую среднеквадратичную ошибку: ridge просто играет не по этим правилам и допускает смещение. А при гетероскедастичности условие σ²I нарушается, и вывод больше не следует.

Продолжить чтение: О. А. Демидова, НИУ ВШЭ - классическая линейная регрессия ↗

От остатков к доверительным интервалам

Мы знаем, что Cov(β̂|X)=σ²(XᵀX)⁻¹. Одна проблема: σ² нам никто не сообщил. Придётся оценить её по остаткам. Пусть n>p и выполнены условия прошлого раздела. Остаток e=(I−P)ε; матрица M=I−P симметрична, идемпотентна и имеет ранг n−p.

Почему делим на n−p

1

$$\mathrm{SSE} = e^\top e = \varepsilon^\top M \varepsilon$$

Пользуемся M²=M и MX=0: истинные веса из остатков исчезают.

2

$$\mathbb{E}[\varepsilon^\top M \varepsilon \mid X] = \sum_i \sum_j M_{ij} \mathbb{E}[\varepsilon_i \varepsilon_j \mid X] = \sigma^2 \operatorname{tr}(M)$$

При нулевом среднем и Ω=σ²I выживают только диагональные слагаемые.

3

$$\operatorname{tr}(M) = n - p \quad \Longrightarrow \quad \mathbb{E}[\mathrm{SSE} \mid X] = (n-p)\sigma^2$$

У P ровно p собственных значений, равных 1, поэтому у M=I−P единиц n−p, а остальные - нули.

4

$$s^2 = \frac{\mathrm{SSE}}{n-p} \quad \Longrightarrow \quad \mathbb{E}[s^2 \mid X] = \sigma^2$$

p оценённых параметров «съели» p степеней свободы. Поэтому MSE=SSE/n систематически занижает σ²: модель подогнана под те же точки и выглядит точнее, чем есть.

Теперь добавим нормальность ε|X~N(0,σ²I). Тогда β̂|X~N(β₀,σ²(XᵀX)⁻¹). А SSE/σ² после ортогонального поворота превращается в сумму квадратов n−p независимых стандартных нормальных величин, то есть имеет распределение χ² с n−p степенями свободы.

От нормального числителя к t-статистике

1

$$\operatorname{Cov}(A\varepsilon, M\varepsilon \mid X) = \sigma^2 AM = 0$$

AM=0. Совместно нормальные векторы с нулевой ковариацией независимы, поэтому β̂ не зависит от s².

2

$$Z_j = \frac{\widehat{\beta}_j - \beta_{0,j}}{\sigma \sqrt{[(X^\top X)^{-1}]_{jj}}} \sim \mathcal{N}(0,1)$$

Стандартизуем одну координату.

3

$$T_j = \frac{Z_j}{\sqrt{(\mathrm{SSE}/\sigma^2)/(n-p)}} \sim t_{n-p}$$

Отношение нормальной величины к корню из независимой нормированной χ^2 имеет распределение Стьюдента. (Того самого, который на самом деле Госсет из пивоварни Guinness.)

4

$$\widehat{\beta}_j \pm t_{1-\alpha/2,n-p}\, s\sqrt{[(X^\top X)^{-1}]_{jj}}$$

Переворачиваем неравенство $|T_j| \le$ квантиль и получаем доверительный интервал уровня $1-\alpha$.

Теперь самая частая ошибка в интерпретации. «95%» - это доля интервалов, которые накроют фиксированный истинный параметр, если повторять эксперимент много раз. Это *не* вероятность того, что параметр лежит в уже посчитанном частотном интервале. Проверка гипотезы $H_0: \beta_j = c$ использует $|(\hat{\beta}_j - c)/\mathrm{SE}_j|$ и ту же t-квантиль. И статистическая значимость - это не «большой эффект» и уж точно не причинность.

Без нормального шума эти t-интервалы на малой выборке в общем случае не точны. Асимптотическим интервалам нужны условия ЦПТ и подходящая оценка ковариации. А при $n \le p$ формула s^2 с делением на $n-p$ вообще не работает.

22 / СРЕДНЕЕ И НОВЫЙ ОТВЕТ

Почему новый ответ предсказать сложнее, чем среднее

Есть два очень похожих вопроса, которые постоянно путают. «Какой *средний* балл у всех, кто готовился 2.5 часа?» и «Какой балл получит *конкретный* Вася, который готовился 2.5 часа?» Во втором случае к неуверенности в весах добавляется ещё и личный шум Васи.

Формально: пусть x_0 - новый столбец из p признаков, включая единицу, $\mu_0 = x_0^\top \beta_0$ и $\hat{\mu}_0 = x_0^\top \hat{\beta}$. При той же нормальной модели и независимом новом шуме ε_0 дисперсии равны:

$$\mathrm{Var}(\hat{\mu}_0 - \mu_0 \mid X, x_0) = \sigma^2 h_0, \quad h_0 = x_0^\top (X^\top X)^{-1} x_0,$$
$$\mathrm{Var}(Y_0 - \hat{\mu}_0 \mid X, x_0) = \sigma^2 (1 + h_0)$$

$Y_0 = \mu_0 + \varepsilon_0$: к неуверенности в среднем добавляется дисперсия нового независимого шума σ^2.

$$\text{Среднее:} \quad \hat{\mu}_0 \pm t_{1-\alpha/2,n-p}\, s\sqrt{h_0},$$
$$\text{Новый ответ:} \quad \hat{\mu}_0 \pm t_{1-\alpha/2,n-p}\, s\sqrt{1 + h_0}$$

Посчитаем. В одномерном случае $h_0 = 1/n + (x_0 - \bar{x})^2 / S_{xx}$. В нашем примере $s^2 = 1.8/2 = 0.9$. При $x_0 = 2.5$ получаем $h_0 = 0.25$ и $\hat{\mu}_0 = 3.5$. С $t_{0.975,2} \approx 4.303$ интервал для среднего - примерно [1.46,5.54], а для нового ответа - [−1.06,8.06]. Отрицательный балл, ага. Четыре точки дают очень мало уверенности.

Чем дальше x_0 от $\bar{x}$, тем шире оба интервала. Но помните: они описывают неуверенность *внутри принятой модели*. Если за пределами train зависимость меняется, даже широкий гауссовский интервал окажется самоуверенным. А отрицательная нижняя граница для заведомо неотрицательного ответа - скорее сигнал, что модель тут неуместна, чем повод молча обрезать интервал по нулю.

23 / НЕОДИНАКОВЫЙ И ЗАВИСИМЫЙ ШУМ

Что, если шум у всех разный?

Вернёмся к квартирам. Ошибка прогноза цены однушки на окраине - плюс-минус пара сотен тысяч. Для пентхауса в Москва-Сити - плюс-минус пара десятков миллионов. Шум с разной дисперсией называют **ГЕТЕРОСКЕДАСТИЧНЫМ**. (Да, это слово нужно уметь выговорить на экзамене.)

При $\Omega \neq \sigma^2 I$ оценка $\hat{\beta}$ остаётся несмещённой, если $E[\varepsilon|X] = 0$. А вот классическая формула ковариации врёт; правильная - $(X^TX)^{-1}X^T\Omega X(X^TX)^{-1}$. В общем случае Ω может иметь разные дисперсии на диагонали и ненулевые ковариации между строками.

Обобщённый МНК при известной $\Omega \succ 0$

1 $$Q(\beta) = (y - X\beta)^\top \Omega^{-1} (y - X\beta)$$

Штрафуем остатки с учётом их масштаба и зависимости: шумным наблюдениям - меньше доверия.

2 $$dQ = -2(y - X\beta)^\top \Omega^{-1} X \, d\beta$$

Ω^{-1} симметрична и от β не зависит.

3 $$\hat{\beta}_{\text{GLS}} = (X^\top \Omega^{-1} X)^{-1} X^\top \Omega^{-1} y$$

При полном столбцовом ранге $X^T\Omega^{-1}X$ положительно определена, так что обращаем смело.

4 $$X^* = \Omega^{-1/2} X, \quad y^* = \Omega^{-1/2} y, \quad \operatorname{Cov}(\varepsilon^* \mid X) = I$$

После «отбеливания» шум становится обычным, и это снова МНК. Значит, работает теорема Гаусса-Маркова.

5 $$\operatorname{Cov}(\hat{\beta}_{\text{GLS}} \mid X) = (X^\top \Omega^{-1} X)^{-1}$$

Линейное преобразование шума даёт ковариацию оценки.

Частный случай Ω=diag(σᵢ²) - **ВЗВЕШЕННЫЙ МНК**: минимизируем Σeᵢ²/σᵢ². Чем точнее наблюдение, тем больше его вес. Формулы не меняются, если Ω известна с точностью до общего положительного множителя.

$$\widehat{V}_{\mathrm{HC0}} = (X^\top X)^{-1} X^\top \operatorname{diag}(e_i^2) X (X^\top X)^{-1}$$

Оценка ковариации, робастная к гетероскедастичности. Веса МНК она не меняет - только стандартные ошибки.

HC0 - асимптотическая оценка, а не гарантия для любых четырёх строк. Ей нужны независимые наблюдения, подходящие моменты и отсутствие доминирующих точек при росте n. Для временной зависимости используют HAC-оценки, для групповой - кластерные. Просто подставить eᵢ² в HC0 при зависимых строках недостаточно.

24 / СОСТОЯТЕЛЬНОСТЬ И СМЕЩЕНИЕ

Чего не исправит даже бесконечная выборка

Популярная надежда: «Соберём побольше данных, и всё само станет правильно». Иногда так и есть. Иногда - нет, и это обиднее всего. Разберёмся, когда.

Когда МНК приближается к истинным весам

1 $$\widehat{\beta} - \beta_0 = (X^\top X/n)^{-1} (X^\top \varepsilon/n)$$

Переписываем ошибку оценки как произведение двух средних по наблюдениям.

2 $$X^\top X/n \xrightarrow{P} Q \succ 0, \qquad X^\top \varepsilon/n \xrightarrow{P} 0$$

Достаточные условия: например, i.i.d. строки, конечные вторые моменты, E[xᵢεᵢ]=0 и невырожденная E[xᵢxᵢᵀ].

3 $$\widehat{\beta} \xrightarrow{P} \beta_0$$

Обращение непрерывно около невырожденной Q, а второй множитель уходит в ноль.

НЕСМЕЩЁННОСТЬ - свойство среднего на конечной выборке, **СОСТОЯТЕЛЬНОСТЬ** - предел при n→∞. Одно не заменяет другое. А при E[xε]≠0 предел будет β₀+Q⁻¹E[xε]: чем больше данных, тем *точнее* мы оцениваем *неправильный* коэффициент. Уверенно и мимо.

$$Y = a_0 U + \gamma Z + b_0 + \varepsilon, \quad \mathrm{Cov}(U, \varepsilon) = 0,$$

$$\text{без признака } Z: \quad a^* = a_0 + \gamma \frac{\mathrm{Cov}(U, Z)}{\mathrm{Var}(U)}$$

Достаточно одного коррелированного пропущенного фактора, чтобы наклон поехал. Это точный вывод из ковариационной формулы - той самой, что я просил запомнить.

Пример: Z - насколько ученик был подготовлен ещё до курса. Он влияет и на часы подготовки, и на балл. Не включили Z в модель - и коэффициент при часах приписывает себе чужие заслуги.

Ошибки измерения признака тоже коварны. Если вместо U мы наблюдаем W=U+δ, где δ имеет нулевое среднее и независима от U и ε, то регрессия Y=a₀U+b₀+ε на W имеет наклон a₀Var(U)/(Var(U)+Var(δ)). Он прижат к нулю. Ни регуляризация, ни лишние итерации это смещение не уберут.

25 / RIDGE: ТОЧНАЯ ФОРМУЛА

Ridge: штрафуем веса, но не смещение

Помните, как веса уползали в разные стороны при почти одинаковых признаках? Самое простое лекарство - запретить им быть большими. Добавим к ошибке штраф за размер весов, и получится **RIDGE-РЕГРЕССИЯ** (она же L2-регуляризация, она же регуляризация Тихонова).

В нашем модуле штрафуются только веса признаков, а смещение b - нет. (Зачем штрафовать модель за то, что средняя цена квартиры в Москве не равна нулю?) Для общей $\beta=(b,w^T)^T$ введём $D=\mathrm{diag}(0,1,\ldots,1)$.

Матричный вывод ridge

1

$$J_\lambda(\beta) = \frac{1}{n}\|X\beta - y\|^2 + \lambda \beta^\top D \beta, \qquad \lambda \geq 0$$

Это обычная MSE плюс $\lambda\Sigma w_j^2$.

2

$$\nabla J_\lambda = \frac{2}{n} X^\top (X\beta - y) + 2\lambda D\beta$$

Штраф добавляет производную только по весам, смещение не трогаем.

3

$$(X^\top X + n\lambda D)\widehat{\beta}_\lambda = X^\top y$$

Множитель n возникает из-за того, что мы усредняем MSE. С SSE его бы не было.

4

$$\widehat{\beta}_\lambda = (X^\top X + n\lambda D)^{-1} X^\top y \qquad (\lambda > 0)$$

$h^T(X^TX+n\lambda D)h=\|Xh\|^2+n\lambda\Sigma h_j^2$: ноль возможен, только если все веса h нулевые, а затем столбец единиц обнуляет и смещение. Для непустой выборки матрица обратима - даже при дублирующихся признаках!

Можно и по-другому: центрируем $X_c=X_0-1\bar{x}^T$ и $y_c=y-\bar{y}1$, решаем $\hat{w}\lambda=(X_c^TX_c+n\lambda I)^{-1}X_c^Ty_c$, а потом находим $\hat{b}\lambda=\bar{y}-\bar{x}^T\hat{w}\lambda$. Так сразу видно, почему штраф не тянет средний прогноз к нулю.

26 / BIAS-VARIANCE ВЕСОВ

Bias и variance весов: бесплатных обедов не бывает

Ridge выглядит как читерство: добавили штраф - и всё стало устойчивым. Но бесплатных обедов не бывает, так что посмотрим, чем именно мы платим. Рассмотрим центрированную задачу для весов, $A=X_c^TX_c$, $k=n\lambda>0$. Условно на дизайн предполагаем $E[\varepsilon]=0$ и $Cov(\varepsilon)=\sigma^2 I$ до центрирования; в произведении $X_c^T\varepsilon$ центрирование шума ничего не меняет.

$$\mathbb{E}[\widehat{w}_\lambda \mid X] - w_0 = -k(A+kI)^{-1}w_0,$$
$$\operatorname{Cov}(\widehat{w}_\lambda \mid X) = \sigma^2(A+kI)^{-1}A(A+kI)^{-1}$$

Первая формула - это bias: ridge в среднем промахивается. Она получается из $E[\hat{w}\lambda]=(A+kI)^{-1}Aw_0$ и равенства $A=(A+kI)-kI$. Вторая - variance, разброс от выборки к выборке; она следует из правила $Cov(B\varepsilon)=B\,Cov(\varepsilon)\,B^T$.

$$d_j > 0: \quad \mathrm{bias}_j = -\frac{k\theta_j}{d_j+k}, \quad \mathrm{variance}_j = \frac{\sigma^2 d_j}{(d_j+k)^2},$$
$$\mathrm{MSE}_j = \frac{k^2\theta_j^2 + \sigma^2 d_j}{(d_j+k)^2}$$

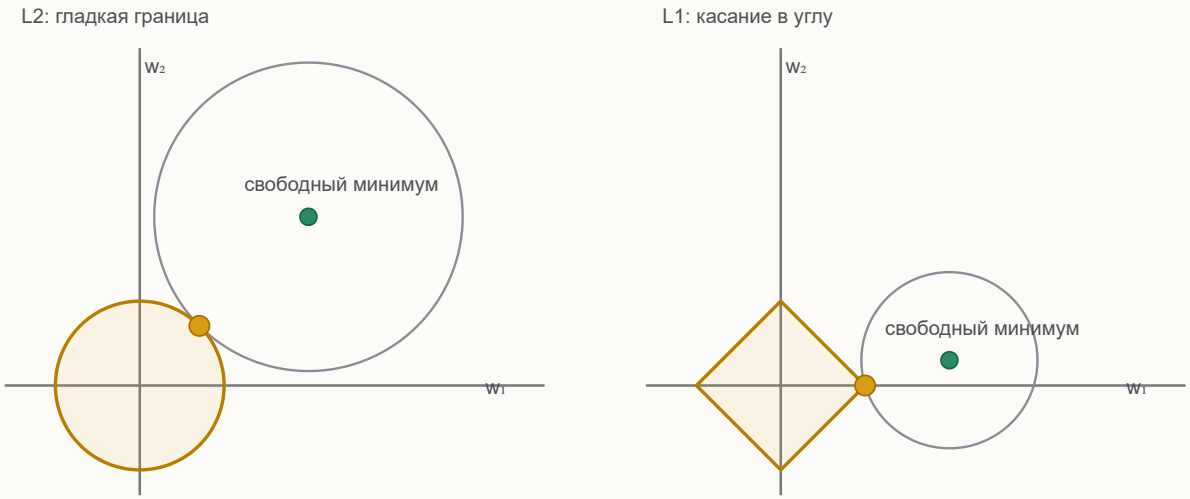
θ_j - истинный коэффициент в этом собственном направлении. Для сравнения: у МНК $variance_j=\sigma^2/d_j$ и $bias_j=0$.

Вот и весь торг. При $d_j\approx0$ дисперсия МНК огромна, а ridge её резко уменьшает. Но если истинный θ_j большой, слишком сильный штраф даст заметный bias. Поэтому универсального λ для всех задач нет, его подбирают на validation. А в сингулярном направлении $d_j=0$ данных про θ_j нет вообще: ridge просто ставит ноль, а не «восстанавливает истину».

Через SVD $X_c=U\Sigma V^T$ картина ещё нагляднее: множитель в направлении j меняется с $1/s_j$ у МНК на $s_j/(s_j^2+n\lambda)$ у ridge. Маленькие сингулярные значения больше не взрывают решение - вот и вся магия.

L1 против L2: почему Lasso умеет обнулять веса

Если в ridge заменить квадраты весов на модули, получится **LASSO** (L1-регуляризация). Казалось бы, мелочь. Но у Lasso есть суперспособность: он может сделать вес *ровно* нулевым, то есть сам выкинуть ненужный признак. Ridge так не умеет: он прижимает веса к нулю, но почти никогда не обнуляет. Почему? Сначала картинка:



Частный случай квадратичной ошибки с круговыми линиями уровня. Жёлтая граница - допустимые веса; зелёная точка - минимум без ограничения. На L2 оптимум имеет две ненулевые координаты. На L1 в показанном примере $w_2=0$. Это иллюстрация; общее обоснование разреженности даёт субградиент ниже.

Теперь строго. У модуля в нуле излом, и обычной производной там нет. Поэтому используем **СУБГРАДИЕНТ** - множество всех допустимых «наклонов» в точке излома.

Условие оптимума Lasso

1 $$\min_w \left[J(w) + \lambda \sum_j |w_j| \right]$$

В центрированной задаче свободный член восстанавливается отдельно, его не штрафуем.

2 $$\partial |w_j| = \{\operatorname{sign}(w_j)\}\ (w_j \neq 0), \qquad \partial |0| = [-1, 1]$$

Вне нуля всё как обычно, а в нуле у модуля целый отрезок возможных наклонов.

3 $$0 \in \partial_j J + \lambda \partial |w_j|$$

Для выпуклой функции это необходимое и достаточное условие оптимума по координате при остальных зафиксированных.

4 $$w_j = 0 \text{ допустим в оптимуме} \iff |\partial_j J| \le \lambda$$

Вот и секрет: L1 может «погасить» ненулевой градиент ошибки прямо в нуле, если тот не слишком большой. У гладкого L2 производная штрафа в нуле равна нулю, поэтому при любом ненулевом градиенте ошибки вес из нуля уйдёт.

Особенно красиво всё выглядит, когда признаки ортонормированы: $X_c^TX_c/n=I$. Тогда при $c=X_c^Ty_c/n$ получаем $J(w)=\Sigma_j(w_j-c_j)^2+\text{const}$, и условие выше даёт $\hat{w}_j=\text{sign}(c_j)\max(|c_j|-\lambda/2,0)$. Порог именно $\lambda/2$, потому что у нас MSE без множителя 1/2 (снова бухгалтерия). При коррелированных столбцах координаты уже не независимы.

Вывод мягкого порога для одной координаты

1 $$w_j > 0: \quad 2(w_j - c_j) + \lambda = 0 \implies w_j = c_j - \lambda/2$$

Эта ветка согласована со знаком w_j только при $c_j>\lambda/2$.

2 $$w_j < 0: \quad 2(w_j - c_j) - \lambda = 0 \implies w_j = c_j + \lambda/2$$

Отрицательная ветка требует $c_j<-\lambda/2$.

3 $$w_j = 0: \quad 0 \in -2c_j + \lambda[-1,1] \iff |c_j| \le \lambda/2$$

Если ни одна ненулевая ветка не подходит, ноль оказывается внутри отрезка субградиентов. Три случая - одна формула soft-thresholding: маленькие коэффициенты обнуляются, большие сдвигаются к нулю на $\lambda/2$.

Две оговорки. Из нескольких коррелированных признаков L1 часто выбирает один, но это не доказывает, что именно он причинно важен: возможно, ему просто повезло. И штрафы зависят от единиц измерения, так что масштабирование перед ridge и lasso должно быть осмысленным.

28 / БАЙЕСОВСКИЙ ВЗГЛЯД

Байесовский взгляд: MAP и веса после данных

До сих пор веса были фиксированными неизвестными числами. Байесовцы смотрят иначе: раз мы не знаем веса, опишем своё незнание распределением. До данных это **PRIOR** (априорное распределение), после - **POSTERIOR** (апостериорное). И внезапно окажется, что ridge - это байесовский вывод, просто в другой одежде.

Рассмотрим модель $y|\beta,X\sim N(X\beta,\sigma^2 I)$ с известной σ^2 и собственным нормальным prior $\beta\sim N(m_0,V_0)$, $V_0>0$.

Дополняем квадрат в апостериорной плотности

1 $$-2\log p(\beta \mid X, y) = \frac{\|y - X\beta\|^2}{\sigma^2} + (\beta - m_0)^\top V_0^{-1}(\beta - m_0) + \text{const}$$

Формула Байеса: posterior пропорционален likelihood × prior. Берём −2log, чтобы произведение стало суммой.

2 $$V_n^{-1} = \frac{X^\top X}{\sigma^2} + V_0^{-1}, \qquad h = \frac{X^\top y}{\sigma^2} + V_0^{-1} m_0$$

Раскрываем скобки: квадратичная по β часть равна $\beta^\top V_n^{-1}\beta - 2\beta^\top h$.

3 $$m_n = V_n h,$$
$$\beta^\top V_n^{-1}\beta - 2\beta^\top h = (\beta - m_n)^\top V_n^{-1}(\beta - m_n) + \text{const}$$

Дополняем до полного квадрата, как в школе, только с матрицами. Сразу видны и центр, и кривизна.

4 $$\beta \mid X, y \sim \mathcal{N}(m_n, V_n), \qquad \widehat{\beta}_{\text{MAP}} = \mathbb{E}[\beta \mid X, y] = m_n$$

Posterior снова нормальный. Для этой модели мода совпадает со средним; в общем случае это не так.

5 $$Y_0 \mid x_0, X, y \sim \mathcal{N}(x_0^\top m_n, \sigma^2 + x_0^\top V_n x_0)$$

Интегрируем неопределённость весов и добавляем независимый шум нового ответа.

$$w \sim \mathcal{N}(0, \tau^2 I) \quad \Longrightarrow \quad \lambda_{\text{MSE}} = \frac{\sigma^2}{n\tau^2}$$

Умножаем отрицательный log-posterior на $2\sigma^2/n$. Если бы loss был SSE, а не MSE, коэффициент был бы σ^2/τ^2. Узкий prior (маленькое τ) - сильная регуляризация.

Чтобы получить ровно ridge из модуля, где b не штрафуется, ставим нормальный prior только на w и плоский prior на b. Плоская плотность на всей прямой не нормируется, так что это *несобственный* prior, а не подстановка в $V_0 \succ 0$. Для непустой выборки posterior всё равно остаётся собственным благодаря столбцу единиц и штрафу на все веса.

А лапласовский prior на w даёт L1-штраф, то есть Lasso. Только не путайте его с лапласовским *шумом*: prior меняет регуляризацию, а шум - loss на данных. И ещё: байесовский интервал имеет вероятностный смысл относительно posterior, и его корректность зависит в том числе от выбранного prior и модели данных.

Продолжить чтение: Яндекс Учебник - байесовский подход к оцениванию ↗

29 / РАЗЛОЖЕНИЕ ОШИБКИ ПРОГНОЗА

Из чего состоит ошибка прогноза: bias² + variance + noise

Это, пожалуй, самая известная формула ML после y=kx+b. Её любят рисовать на собеседованиях в виде мишени с дырочками. Давайте не рисовать, а докажем.

Зафиксируем новый x. Пусть f(x)=E[Y|x], σ²(x)=Var(Y|x), обучающая выборка D независима от нового ответа, а все нужные вторые моменты конечны. Обозначим m=E_D[f̂_D(x)] - средний прогноз по всем возможным обучающим выборкам.

Раскрываем квадрат и проверяем смешанные члены

1 $$\widehat{f}_D(x) - Y = (\widehat{f}_D(x) - m) + (m - f(x)) - \varepsilon$$

Три слагаемых: разброс обученной модели, систематический промах и шум нового ответа.

2 $$\mathbb{E}_D[\widehat{f}_D - m] = 0, \qquad \mathbb{E}[\varepsilon \mid x] = 0$$

Средние двух случайных слагаемых равны нулю.

3 $$\mathbb{E}[(\widehat{f}_D - m)\varepsilon \mid x] = 0$$

Новый шум независим от обучения и в среднем равен нулю. Остальные смешанные члены обнуляются так же.

4 $$\mathbb{E}_{D,Y|x}[(\widehat{f}_D(x) - Y)^2] = (m - f(x))^2 + \mathrm{Var}_D(\widehat{f}_D(x)) + \sigma^2(x)$$

Остаются ровно три квадратичных вклада. Никаких «примерно».

Это точное равенство при указанных условиях. Слагаемое **noise** нельзя уменьшить настройкой весов при том же наборе информации. Можно только поменять саму постановку: собрать дополнительные полезные признаки или измерять точнее. Регуляризация играет на первых двух слагаемых, а шум из мира она не удаляет. (А жаль.)

30 / НЕЛИНЕЙНОСТЬ И НОВЫЕ ПРИЗНАКИ

Когда прямой мало: новые признаки

Помните параболу Y=U², которую прямая в упор не видела из-за нулевой ковариации? Лечится это одной строчкой: добавим признак φ(U)=(U,U²). Теперь модель b+w₁U+w₂U² содержит правильную функцию. Матрица X поменялась, но все доказательства МНК остались в силе: параметры по-прежнему входят линейно.

Только не увлекайтесь. Полиномы высокой степени часто дают почти зависимые столбцы и легко переобучаются. Степень, преобразования и λ выбирают на validation. Категориальные признаки кодируют индикаторами, и тут ловушка: полный one-hot для одной категории вместе со свободным членом даёт точную линейную зависимость столбцов (сумма индикаторов равна столбцу единиц). Поэтому одну базовую категорию обычно выкидывают.

И главное: низкий train-MSE ещё не означает адекватную модель. При добавлении признаков train-SSE у МНК может только уменьшиться: старое решение никуда не делось, достаточно поставить новым весам ноль. Это алгебра, а не доказательство того, что модель стала лучше обобщать.

31 / ДРУГИЕ LOSS И МЕТРИКИ

MSE, MAE и квантили: разные loss - разные вопросы

Мы доказали, что квадрат ведёт к условному среднему. А если взять модуль? Тогда ответом будет **МЕДИАНА**. Для абсолютной ошибки при E[|Y||x]<∞ и непрерывной условной функции распределения F_x производная E[|Y−c||x] по c равна 2F_x(c)−1, и ноль получается ровно на медиане. При атомах вместо производной берут субградиент, и медиана может быть не единственной.

От модуля к условной медиане

1 $$\frac{\partial |y-c|}{\partial c} = \begin{cases} 1, & y < c, \\ -1, & y > c \end{cases}$$

Разбираем две линейные ветки модуля. Точка y=c при непрерывном распределении имеет нулевую вероятность.

2 $$\frac{\partial \mathbb{E}[|Y-c| \mid x]}{\partial c} = P(Y < c \mid x) - P(Y > c \mid x)$$

Разностные отношения модуля по абсолютной величине не больше единицы, поэтому теорема о мажорируемой сходимости разрешает занести предел под ожидание.

3 $$P(Y < c \mid x) - P(Y > c \mid x) = F_x(c) - (1 - F_x(c)) = 2F_x(c) - 1$$

Производная равна нулю при F_x(c)=1/2 - это и есть медиана. Выпуклость абсолютной ошибки гарантирует глобальный минимум.

$$\rho_q(e) = e(q - \mathbf{1}[e < 0]), \qquad e = y - \hat{y}, \quad q \in (0,1),$$
$$\frac{\partial \mathbb{E}[\rho_q(Y-c) \mid x]}{\partial c} = F_x(c) - q$$

Квантильный (pinball) loss. При непрерывности оптимум - условная q-квантиль. Знак остатка важен: если взять ŷ−y, формулу придётся переписать.

Откуда F_x(c)−q? У квантильной ошибки производная по c равна 1−q при y<c и −q при y>c. Ожидание даёт (1−q)F_x(c)−q(1−F_x(c))=F_x(c)−q. Производная ограничена, так что перенос предела под ожидание снова законен. При атомах условие оптимума записывается как F_x(c−)≤q≤F_x(c).

Ещё немного зоопарка. RMSE=√MSE возвращает ошибку в единицы ответа и без штрафа имеет тот же минимум. Но со штрафом √MSE+λ‖w‖² и MSE+λ‖w‖² - уже разные задачи. MAE меньше реагирует на выбросы в ответах, но от экстремальных признаков сама по себе не спасает.

Huber loss равна e²/2 при |e|≤δ и δ(|e|−δ/2) иначе: возле нуля ведёт себя как квадрат, в хвостах - как модуль. Лучшее из двух миров. MAPE нестабильна около нулевого таргета (делить на ноль всё ещё нельзя). Итог: метрику выбирают по цене ошибки в реальной задаче, а не по тому, у кого производная красивее.

32 / ПРОВЕРКА НА НОВЫХ ДАННЫХ

Минимум на train - ещё не победа

Мы потратили кучу сил, чтобы доказать, что МНК находит минимум ошибки на train. Плохая новость: это ничего не говорит о качестве на будущих данных. Помните «очень дорогую зубрёжку» из самого первого урока? Вот она.

Поэтому данные делят на три части: **train** - чтобы подобрать веса, **validation** - чтобы выбрать признаки, λ и момент остановки, **test** - для финальной проверки. Если многократно выбирать модель по test, он перестаёт быть независимой оценкой и превращается во второй validation.

Для временных данных разбиение должно уважать время: предсказывать прошлое по будущему - читерство, которое в продакшене не повторится. Если несколько строк относятся к одному человеку или устройству, делить часто нужно группами. А нормализацию, заполнение пропусков и отбор признаков обучаем только на train, в том числе внутри каждого фолда кросс-валидации.

33 / ЧТО ОЦЕНИВАЕТ VALIDATION

Что на самом деле оценивает validation

Чтобы не говорить о «качестве на будущих данных» на пальцах, введём **РИСК** - ожидаемую ошибку на новых объектах из того же распределения P, и его оценку по validation:

$$R(f) = \mathbb{E}_{(U,Y)\sim P}[(Y - f(U))^2],$$
$$\widehat{R}_{\text{val}}(f) = \frac{1}{m}\sum_{i=1}^{m}(y_i - f(u_i))^2$$

Если модель фиксирована и не видела validation, а validation - i.i.d. выборка из P с конечным риском, то $E[\hat{R}_{val}|f]=R(f)$. Вот почему validation вообще работает. Но если по той же выборке выбирать победителя среди многих моделей, его оценка становится оптимистичной: он победил в том числе за счёт удачного шума.

А если будущее распределение меняется (цены на квартиры в 2016 и 2026 годах - немножко разные), прежний риск относится уже к другому P. От такого сдвига не защищает ни теорема Гаусса-Маркова, ни сколь угодно маленький градиент.

34 / ОСТАТКИ И ОГРАНИЧЕНИЯ

Модель обучилась. Что дальше?

Обучили модель, получили веса. Расслабляться рано: теперь нужно посмотреть на остатки. Они часто подсказывают, какие из наших предположений о мире не выполняются. Вот небольшой справочник:

Диагностика гипотез, а не автоматические диагнозы

Наблюдение	Что проверить
Изгиб на графике e против ŷ	Возможно, условное среднее нелинейно; попробовать преобразования признаков.
Разброс остатков растёт	Возможна гетероскедастичность; классические SE могут врать.
Ошибки идут сериями во времени	Возможна зависимость наблюдений; проверить временной split и ковариацию.
Одна точка сильно меняет веса	Проверить выброс ответа и leverage - необычный вектор признаков.
Веса скачут, прогноз почти тот же	Проверить ранг и маленькие сингулярные значения.

И пара формул, чтобы не делать поспешных выводов:

$$e = (I - P)\varepsilon \quad \Longrightarrow \quad \mathrm{Cov}(e \mid X) = \sigma^2(I - P),$$
$$\mathrm{Var}(e_i \mid X) = \sigma^2(1 - P_{ii})$$

Даже при независимом одинаково распределённом шуме обученные остатки обычно зависимы и имеют разные дисперсии. Сюрприз!

Диагональ P_{ii} называется **LEVERAGE** («рычаг») и зависит только от геометрии признаков. Точка с большим leverage может притянуть прогноз к себе и получить маленький остаток. Поэтому маленький остаток ещё не доказывает, что точка ни на что не влияет: возможно, она как раз перетянула одеяло на себя. И помните: в МНК со смещением средний остаток всегда равен нулю по построению. Использовать это как подтверждение $E[\varepsilon|X]=0$ нельзя.

35 / ПРЕДЕЛЫ ИНТЕРПРЕТАЦИИ

Коэффициент - ещё не причина

Финальное предостережение, и, пожалуй, самое важное. $E[Y|U=x]$ описывает *наблюдаемую* связь: какой ответ мы в среднем видим у объектов с таким признаком. А $E[Y|do(X=x)]$ - средний ответ, если мы *вмешаемся* и принудительно установим значение признака. Это разные вещи, и чтобы они совпали, нужны дополнительные условия и правильный дизайн исследования.

Вспомните формулу пропущенного фактора: коэффициент может быть ненулевым даже при $a_0=0$, если $\gamma Cov(U,Z)\neq 0$. Например, подготовленность до курса влияет и на время, потраченное на задания, и на итоговый результат. Регрессия по времени смешает эти связи. Если заставить ученика сидеть над заданиями вдвое дольше, балл не обязан вырасти так, как обещает коэффициент. Значимый коэффициент и высокий R^2 сами по себе причинный эффект не выделяют.

(Продажи мороженого отлично предсказывают число утоплений: обоих больше летом. Запрещать мороженое - плохая идея.)

36 / ПРОВЕРИТЬ ПОНИМАНИЕ

О боже, домашка, нееееет :(

Не переживайте, она короткая. Попробуйте ответить сами и только потом раскрывайте решение. Упражнения не влияют на прогресс и доступны в любой момент.

Вопрос. В выборке все x одинаковы. Почему нельзя назвать единственный наклон?

Потому что $S_{xx}=0$ и столбец x кратен столбцу единиц. При $x=c$ любые a,b с $ac+b=\bar{y}$ дают один и тот же оптимальный прогноз. Определён прогноз на train, но не наклон.

Вопрос. Шум Лапласа имеет среднее 0 и одинаковую дисперсию. МНК стал смещённым?

Нет, если $E[\varepsilon|X]=0$ и X полного столбцового ранга. При независимых ошибках МНК остаётся BLUE. Изменилось другое: MLE теперь соответствует MAE, а не MSE, и точные нормальные t-интервалы без дополнительных аргументов применять нельзя.

Вопрос. Сделали два экземпляра каждой строки. Нужно ли вдвое усилить λ в MSE + λ‖w‖²?

Нет. MSE и штраф остаются теми же, значит, оптимум не меняется: в формулах одновременно удваиваются X^TX, X^Ty и $n\lambda$. Но копирование не создаёт независимых данных, поэтому считать, что неопределённость весов уменьшилась как от новых наблюдений, нельзя.

Что почитать дальше

Эта глава - самостоятельный пересказ: доказательства собраны в одной системе обозначений, с собственным числовым примером и явными условиями применимости. Если пойдёте читать источники, будьте готовы: там может отличаться знак остатка, буквы a и b могут поменяться местами, а множители 1/n и 1/2 то появляются, то исчезают. Сравнивайте функцию потерь целиком, а не отдельные формулы.

РУССКОЯЗЫЧНЫЕ МАТЕРИАЛЫ

Андрей Хлевнюк - «Основы линейной регрессии»: ковариация и геометрия

Яндекс Учебник - линейные модели: МНК и регуляризация

Яндекс Учебник - вероятностный подход: шум и loss

Яндекс Учебник - байесовский подход: prior и posterior

О. А. Демидова, НИУ ВШЭ - Гаусс-Марков, оценки дисперсии и интервалы (PDF)

Если заметили неточность или ошибку - пишите, исправим. Спасибо за внимание!